

FIAP · MBA AI ENGINEERING & MULTI-AGENTS
CLOUD & COGNITIVE ENVIRONMENTS

FinOps

Aula 06 — a última aula: a disciplina de fazer engenharia e economia conversarem.

Os 3 pilares do FinOps

PROF. ISAIAS S. BRITTO

Como vamos passar as próximas 4 horas

00:00 — 01:00

Bloco 1 — FinOps: 3 pilares · Cost Management + Advisor

Inform → Optimize → Operate + lab: gastos reais da sua assinatura + budget alert

01:00 — 02:00

Bloco 2 — Otimização + LGPD · Pricing Calculator

Reserved / Spot / Right-sizing / lifecycle / egress + lab: TCO em escala real

02:00 — 02:20

Break

20 minutos de pausa

02:20 — 04:25

Bloco 3 — FinOps em AI e Resumo do Conteúdo

Teoria Apenas - Token economics, embeddings em escala, GPU, modelos idle, cache semântico

Como vamos passar as próximas 4 horas

00:00 — 01:00

Bloco 1 — FinOps: 3 pilares · Cost Management + Advisor

Inform → Optimize → Operate + lab: gastos reais da sua assinatura + budget alert

01:00 — 02:00

Bloco 2 — Otimização + LGPD · Pricing Calculator

Reserved / Spot / Right-sizing / lifecycle / egress + lab: TCO da QC em escala real

02:00 — 02:10

Break

10 minutos de pausa

02:10 — 03:25

Bloco 3 — FinOps em AI

Token economics, embeddings em escala, GPU, modelos idle, cache semântico

03:25 — 04:00

Bloco 4 — Reservado para dúvidas sobre trabalhos

Sem novo conteúdo — facilitação pura: consolidar o projeto integrado final com o professor

Engenharia é decisão **econômica**.

Vocês passaram cinco aulas conhecendo os principais fundamentos de Nuvem e Arquitetura.

A arquitetura mais bonita do mundo pode falir a empresa se o custo escapar do controle.
FinOps é a outra metade do trabalho.



FinOps é defender economicamente o que será construído

01



FinOps: os 3 pilares

Inform → Optimize → Operate.

O que é FinOps, de onde veio, quem faz — e por que vocês, engenheiros, já fazem parte disso desde a Aula 1.

FinOps não é "cortar custo"

" (FinOps é) Disciplina **cultural e prática** que combina engenharia, finanças e negócios para maximizar **valor de negócio** em workloads de cloud." — FinOps Foundation

✗ NÃO É Ficar pão-duro

Gastar \$100 e gerar \$500 não é vitória — é oportunidade desperdiçada.

✓ É Otimizar valor (custo × benefício)

Gastar **\$1.000** e gerar **\$10.000** é melhor que gastar \$100 e gerar \$500. FinOps mede o gasto para tomar decisão informada.

Os 3 pilares: Inform → Optimize → Operate

1 · INFORM

Visibilidade

Quem gasta o quê, onde, quando.

• Cost Mgmt · tags · dashboards

2 · OPTIMIZE

Ação

Reduzir custo sem perder qualidade.

• Advisor · Reserved · lifecycle

3 · OPERATE

Cultura

KPIs, budgets, retros mensais.

"Every engineer is FinOps now."

• KPIs · budgets · retros

A maioria das empresas **para no Inform**.
Quem chega no Operate ganha vantagem competitiva.

Os 3 níveis de maturidade em FinOps

1 · Crawl

Controle superficial

Budget alerts + tags básicas

• Maioria das empresas

2 · Walk

Empresas começam a otimizar

Reserved Instances + lifecycle policies +
dashboards

• Empresas medianas

3 · Run

Análise de retorno por time

Retros mensais + chargeback +
FinOps Engineer dedicado

• Empresas líderes

Onde a sua empresa está hoje

Quem trabalha com FinOps na Cloud

Cada Engenheiro

Você

"Every engineer is FinOps now" —
decisões de design refletem em custo.

- Responsável pela arquitetura

Analista de Custo

Cloud Cost Analyst

Relatórios para diretoria, modelagem
de custo, forecasting.

- Perfil Analítico

FinOps Engineer

Mensura retorno sobre custo

Cost intelligence automatizada:
dashboards, alertas, pipelines de
custo. Indica melhorias.

- Perfil Consultivo

Tag aplicada na criação do recurso via **Terraform** = **FinOps básico**.
Vocês já fazem isso desde a Aula 1.



**Sem tag, não há identificação;
Sem identificação, não há alocação de custo.
Sem alocação, não há **FinOps**.**

NA PRÁTICA

Tag aplicada **na criação** do recurso (Terraform) permite alocar custos por projeto, time, ambiente ou por aula.

VOCÊS JÁ FIZERAM

Tags aula=1, aula=2... aplicadas via TF desde o início — *voilà* , FinOps básico implementado.




Exemplos de TAGS que usamos

```
25  
26     locals {  
27         tags = {  
28             aula          = "3"  
29             disciplina     = "cloud-cognitive"  
30             projeto       = "quantum-commerce"  
31             provisionado  = "terraform"  
32         }  
33     }  
34
```

```
30  
31     locals {  
32         tags = {  
33             aula          = "5"  
34             disciplina     = "cloud-cognitive"  
35             projeto       = "quantum-commerce"  
36             provisionado  = "terraform"  
37         }  
38     }  
39
```

· LORD KELVIN, ADAPTADO ·

O que não pode ser **medido** não pode ser otimizado.




William Thomson: Lord Kelvin
Criador da escala Kelvin



Inform vem antes de Optimize por uma razão: primeiro a régua, depois a tesoura.
É o que o próximo lab faz — medir os gastos reais de vocês.

LAB 1



Cost Management + Advisor + Budget Alert

Antes de continuar, certifique-se de ter à disposição:

- Conta Azure já logada
- Cloud Shell funcionando
- Uma boa xícara de café ☕

Objetivo: Aplicar o **Inform** do FinOps na sua própria assinatura Azure for Students. Identificar onde foi gasto crédito até hoje e configurar um budget alert para o restante.

Passo 1 — Análise de custo da assinatura

1. Portal → busque "Cost Management" → Cost analysis

2. Filtros recomendados:


1. **Date range:** Last 30 days (ou desde o início da disciplina)
2. **Granularity:** Daily
3. **Group by:** Service name (ou "Resource type")

3. Identifique seu top 3 maiores gastadores dos últimos 30 dias

Para a maioria dos alunos, o gasto deve ser pequeno (Free tiers + lifecycle bem aplicado). Se algum item está alto, é um aprendizado real.

Passo 2 — Explore por "Tag"

1. Na mesma view, mude **Group by** para **Tag**
2. Use a tag aula que vocês colocaram desde a Aula 1
3. Veja gastos por aula — qual aula consumiu mais?



Objetivo: Aplicar o **Inform** do FinOps na sua própria assinatura Azure for Students. Identificar onde foi gasto crédito até hoje e configurar um budget alert para o restante.

Passo 3 — Azure Advisor (Optimize)

1. Portal → busque "Advisor"

2. Aba **Cost**


3. Leia as recomendações (provavelmente a lista estará vazia, dado que sempre desprovisionamos os recursos ainda na aula)

Recomendações comuns que aparecem:

- VMs idle (right-sizing)
- Reserved Instances aplicáveis
- Endpoints orphans (provisioned but unused)
- Storage tiers — blob frio em hot tier

Anote nas suas notas para a seção finops/analise-otimizacao.md do projeto final quais recomendações apareceram para sua assinatura.

Lista vazia? Tudo bem — o aprendizado é **saber consultar**



Objetivo: Aplicar o **Inform** do FinOps na sua própria assinatura Azure for Students. Identificar onde foi gasto crédito até hoje e configurar um budget alert para o restante.

Passo 4 — Budget Alert

1. Portal → Cost Management → **Budgets** → + Add

2. Configure:


1. Name: budget-aula06
2. Amount: **\$5** (ou o que restar do seu crédito)
3. Reset period: Monthly
4. **Alert conditions:** 50%, 80%, 100% do budget
5. Alert recipients: seu e-mail

3. Salvar

Final — Discussão (5 min)

Conversa em grupo:

- Algum membro do grupo já passou dos \$50 de crédito? Em quê?
- O que vocês fariam diferente se começassem a disciplina de novo?
- Como esse aprendizado se aplica à arquitetura de uma empresa em escala?



02



FinOps Otimização + LGPD em custo


Reserved, Spot, Right-sizing, lifecycle de storage, o vilão do egress — e o sub-bloco transversal de hoje: LGPD impactando custo .

► Um Datacenter por dentro



PRINCIPAIS CUSTOS DE UM DATACENTER

Custos Computacionais



Custos de Infra Estrutura

- Energia
- Refrigeração
- Segurança física




Custos de Serviço

- Plataformas
- Backups
- Licenças



Com o que você deve se preocupar



O que estou planejando usar da nuvem, utilizará quais recursos?

Quanto "extra" pagarei pela comodidade da administração Serverless?

Qual o ganho de terceirizar a administração?

Lembrete: Armazenamento Bruto Lifecycle — mover blob entre tiers



ECONOMIA

80–90% em logs antigos.

Em escala, lifecycle é **seis dígitos por ano** .

⚠ RETRIEVAL FEE

Archive cobra para **LER** .

Não use para dados quentes.

*E deletar respeita política de retenção.

Lembrete: Compute Bruto

Estratégias de Desconto

ESTRATÉGIA	DESCONTO	RISCO	QUANDO USAR
Pay-as-you-go	0%	Nenhum	Dev/test imprevisível
Reserved Instances	~30–50%	Compromisso 1–3 anos	Workload 24/7 estável
Spot	~60–90%	Pode ser interrompido	Batch, treino de ML
Savings Plan	~25–40%	Compromisso de gasto	Múltiplos serviços, mais flexível
Right-sizing	varia	Nenhum	Sempre

Right-sizing é o **low-hanging fruit** — comece por ele antes de assinar compromisso de 3 anos.

Egress — o vilão silencioso

↓ ENTRANDO NA NUVEM

Grátis

↑ SAINDO DA NUVEM

\$/GB

Varia por região.

A regra: tráfego entrando no Azure é grátis; tráfego saindo é cobrado por gigabyte, variando por provedor e região.

MITIGAÇÃO:

Usar mesma nuvem e região de sistemas existentes, de clientes e de fornecedores, manter cópias reutilizáveis, processar na região e extrair apenas resultados (agregados).



Pergunta para a sala: quem aqui já se **surpreendeu** com cobrança de egress?

TCO - Custo Total de Propriedade

Quanto custa, **por mês**, manter toda a arquitetura rodando em escala real — não apenas um serviço, mas a soma de todos os componentes.

Exemplo, baseado no que vimos.
Quanto custa por mês:

- + Blob Storage (10 TB)
- + Azure SQL
- + Cosmos DB
- + Azure AI Search
- + Functions
- + AI Services
- + Azure ML
- + Application Insights
- + Egress

= custo mensal estimado em produção




LAB 2

+ exercício

Trabalho assistido em grupo - TOC

Antes de continuar, certifique-se de ter à disposição:

- Conta Azure já logada
- Cloud Shell funcionando
- Uma boa xícara de café ☕



AVISO: Este laboratório vale como entrega final de FinOps!
Deve ser feito em grupos nas Breakout rooms ou posteriormente, a critério dos grupos.

Objetivo: Estimar o **custo mensal** da arquitetura completa da Quantum Commerce em **escala real** (não free tier). Este resultado entra no projeto integrado final (seção finops/).

Cenário:

Você é arquiteto cloud apresentando à diretoria da QC. Estime o TCO mensal considerando:

Componente	Volume mensal esperado
Blob Storage	10 TB (5 TB Hot + 3 TB Cool + 2 TB Archive) — imagens + logs
Azure SQL Database	Hyperscale 4 vCores + 100 GB (não free para escala real)
Cosmos DB	4.000 RU/s + 50 GB
Azure AI Search	Standard S1 (3 réplicas, 12 partitions)
Function App	Premium EP1 (sempre warm — 5M req/mês)
Azure AI Services	Multi-service S0: 1M chamadas Language + 5.000h Speech + 500k chamadas Vision
Azure ML	Workspace + Compute B2s ocasional + 1 Online Endpoint Standard_DS3_v2 (24/7)
Application Insights	5 GB de logs/mês
Egress	500 GB/mês saindo para CDN externa

Passo 1 — Adicionar cada serviço

- 1.Em <https://azure.microsoft.com/pricing/calculator>, **adicione um por um** todos os 9 itens acima
- 2.Configure **East US 2** como região para tudo (padrão da disciplina)
- 3.Preencha os volumes da tabela

Passo 2 — Calcular o total

- 1.Role até o final — total mensal em USD
- 2.Converta para BRL (cotação atual ~5,3)
- 3.Anote os 3 itens mais caros

Passo 3 — Otimização hipotética

Para cada item dos top 3, proponha uma otimização:

- Exemplos comuns:
- AI Services Language:** trocar Sentiment por GPT-4o-mini (mais barato em escala se usado smart)
 - ML Endpoint 24/7:** scale-to-zero ou batch endpoint (drops 95% do custo)
 - Egress:** Azure Front Door reduz custos vs CDN externa
 - Function Premium EP1:** ficar em Consumption Y1 se cold start aceitável (volta de \$146/mês para \$0)

Item caro	Otimização proposta	Economia estimada

Passo 4 — Exportar

1. Clique em "**Export**" → **Excel**
2. Salvar como `finops/estimativa-qc.xlsx` no repo privado do grupo
3. Clique em "**Share**" → copiar link
4. Guardar o link no `finops/pricing-calculator-link.md` do projeto final

Passo 5 — Comparar com Reserved Instances

Para os itens 24/7 (SQL, Search, Function Premium se mantido, ML Endpoint):

1. Reabrir a estimativa
2. Em cada item 24/7, mudar para **1 year reserved** ou **3 year reserved**
3. Comparar economia

Reflexão (escrever em `finops/analise-otimizacao.md` do projeto final):

- a) Qual o TCO mensal estimado em USD da arquitetura QC sem otimização?
- b) Qual o TCO otimizado (com suas 3 propostas aplicadas)?
- c) Qual a economia % com Reserved Instances de 1 ano?
- d) **Como você apresentaria esses números ao CFO da QC (em 1 parágrafo)?**

 **Checkpoint L₂:** Você tem estimativa exportada (.xlsx) + análise de 3 otimizações + cenário Reserved?

Passo 4 — Exportar

1. Clique em "**Export**" → **Excel**
2. Salvar como `finops/estimativa-qc.xlsx` no repo privado do grupo
3. Clique em "**Share**" → copiar link
4. Guardar o link no `finops/pricing-calculator-link.md` do projeto final

Passo 5 — Comparar com Reserved Instances

Para os itens 24/7 (SQL, Search, Function Premium se mantido, ML Endpoint):

1. Reabrir a estimativa
2. Em cada item 24/7, mudar para **1 year reserved** ou **3 year reserved**
3. Comparar economia

Reflexão (escrever em `finops/analise-otimizacao.md` do projeto final):

- a) Qual o TCO mensal estimado em USD da arquitetura QC sem otimização?
- b) Qual o TCO otimizado (com suas 3 propostas aplicadas)?
- c) Qual a economia % com Reserved Instances de 1 ano?
- d) **Como você apresentaria esses números ao CFO da QC (em 1 parágrafo)?**

 **Checkpoint L₂+Exercício Final:** Você tem estimativa exportada (.xlsx) + análise de 3 otimizações + cenário Reserved?

Item	Obrigatório?	Pontos máximos
Cabeçalho do grupo + distribuição do trabalho	✔ Sim	1 pt (Critério 4)
🟢 N1 — Exercícios 2 (FinOps)	✔ Sim	7 pts (Critério 1)
🟡 N2 — N/A	N/A	N/A
🔴 N3 — N/A	N/A	N/A
Reflexão coletiva ao final	✔ Sim	2 pt (Critério 5)
Total		10 pts

Sugestão de nome de arquivo: `entrega-grupo-NN-aula06.zip` (substitua NN pelo nome de um integrante).

O que deve conter no arquivo

```
qc-grupo-NN-aula06/
├─ entrega-grupo-aula06.md      # 🌟 documento principal (template em ../template-entrega-grupo.md)
├─ finops/estimativa-qc.xlsx    # exportado do Pricing Calculator (gerado na aula ou após a aula)
├─ finops/pricing-calculator-link.md # com o link compartilhável da estimativa
├─ finops/analise-otimizacao.md  # com top 3 caros + propostas de otimização + comparação com Reserved Instances
└─ README.md                   # Apenas para manter o padrão
```


Resumo do que vimos nas aulas

6 aulas

5 entregas + 1 entrega final

Uma arquitetura cloud real para a Quantum Commerce.

Fundamentos de Nuvem

Processamento Serverless

5 tools prontas para alimentar agentes de verdade

1 tool com Machine Learning

MLOps nível 1

FinOps para finalizar

Ferramentas usadas

Azure Cloud

Azure Machine Learning

Cloud Shell

Pricing Calculator

git

terraform

docker (sem build)

Muitos comandos SH

Isso não é exercício de curso — é **portfólio**.

Levem pro resto do MBA e pra carreira.

A large blue circle is in the top-left corner, and a small pink horizontal bar is just below it.

Obrigado.

Até a próxima

A large pink circle is in the bottom-right corner.