



MBA⁺

**AI Engineering &
Multi Agents**



**MBA⁺**

Data Architecture, Integration and Ingestion

Prof.: Leandro M. Mendes
Email: profleandro.mendes@fiap.com.br

Material de Referência:
Prof.: Ivan Gancev
Email: profivan.gancev@fiap.com.br





LEANDRO MENDES

ESPECIALISTA EM PLATAFORMA DE DADOS

- Bacharel em Desenvolvimento de Sistemas.
- MBA em Arquitetura de Dados & Engenharia de Dados.
- Experiência com Infraestrutura, desenvolvimento e banco de dados.
- Mais de 10 anos em plataforma de dados (Sql, NoSql e BigData).
- Vivência em indústria, e-commerce, varejo, financeiro, etc.
- Data Platform Manager – PetLove & Quinto Andar.
- Arquitetura de dados em consultorias como Accenture & Mckinsey



linkedin.com/in/leandrommendes/

Quem somos???

- Quem **não** trabalha na área de Tecnologia?
- Quem de tecnologia **não** trabalha com dados?
- Quem **nunca** ouviu falar em arquitetura de dados?
- Quem conhece, trabalha ou já trabalhou com algum banco de dados?

Pré-requisitos técnicos esperados para a disciplina...

- **Sistemas Operacionais:** <https://www.alura.com.br/artigos/sistemas-operacionais-conceito-estrutura>
- **Linux CLI (3/4 do curso):** <https://www.alura.com.br/formacao-comecando-linux>
- **Linux:** <https://on.fiap.com.br/local/salavirtual/conteudo-digital.php>
- **Máquinas virtuais:** <https://www.alura.com.br/artigos/virtualbox-maquinas-virtuais>
- **Docker:** <https://www.alura.com.br/curso-online-docker-criando-gerenciando-containers>
- **Git:** <https://www.alura.com.br/curso-online-git-github-controle-de-versao>

Data Architecture, Integration and Ingestion

(O que vamos explorar?)

Aula 1 – 11/ago (ter)

- Sistemas de Gerenciamento de banco de dados
- Estratégias de arquitetura
- Data Warehouse, Data lake, Lakehouse e Data Mesh

Aula 2 – 13/ago (qui)

- Exemplos de Bancos, diferenças e usos:
 - Bancos Relacionais
 - Bancos Colunares

Aula 3 – 20/ago (qui)

- Exemplos de Bancos, diferenças e usos:
 - Bancos chave-valor
 - Bancos de documentos
 - Bancos de Grafos & Vector

Aula 4 – 27/ago (qui)

- Ingestão de dados, tratamentos e manipulações
- Pipeline de dados, governança e qualidade
- Integração de dados
 - Cargas batch, ETL, vantagens e desvantagens

Aula 5 – 03/set (qui)

- Eventos, APIs e casos de uso
- Visualização de dados
- Boas práticas e recomendações

Definição

Dado

Que caracteriza, que qualifica alguma coisa

Arquitetura de dados

Conjunto de regras, políticas e referências que governam como os dados são coletados, transformados e utilizados pelos sistemas de uma empresa

Definições

DAMA (Data Management Association) é uma organização internacional dedicada à gestão de dados e à disseminação de melhores práticas na área. Ela define a arquitetura de dados como um componente crítico na governança e gestão eficaz dos dados dentro de uma organização. A arquitetura de dados segundo a DAMA inclui a criação de modelos de dados, a definição de políticas e padrões de dados, e a garantia de que os dados estão acessíveis e protegidos, atendendo às necessidades de negócios e conformidades regulatórias.

TOGAF (The Open Group Architecture Framework) é um framework de arquitetura empresarial que fornece uma abordagem abrangente para o desenvolvimento e gestão de arquiteturas de TI, incluindo a arquitetura de dados. Segundo o TOGAF, a arquitetura de dados envolve a definição de entidades de dados, seus relacionamentos e fluxos através de sistemas. Ele destaca a importância de alinhar a arquitetura de dados com os objetivos de negócios, garantindo que os dados sejam uma parte integrada e sustentável da infraestrutura tecnológica.

Modelo Canônico

Um modelo canônico de dados é uma representação unificada e padronizada dos dados dentro de uma organização, destinada a facilitar a integração e o intercâmbio de informações entre diferentes sistemas e aplicações. Ele serve como um "padrão ouro" ou referência comum para dados, garantindo consistência, compreensibilidade e interoperabilidade.

Banco de dados

Conjuntos de dados armazenados e organizados para serem acessados com facilidade e segurança.

Tipos de dados

Estruturados

Semi-estruturados

Não estruturados

Dados estruturados

Dados que possuem uma estrutura rígida e pré-definida. Seus formatos determinam tamanhos e capacidades.

Ex: código de barras, CPF, combo-box, QR Code

Dados semi estruturados

Eventualmente estruturado, podendo possuir uma parte com formatação rígida e pré-definida, juntamente com uma parte mutável.

Ex: Arquivos delimitados, XML, e-mails, HTML

Dados não estruturados

Não possui formatação ou estrutura padronizada

Ex: Fotos, vídeos, audios, emojis, sticker do whatsapp, gif

Questão

Quando um dado é armazenado ele passa a ser estruturado?

Sistemas de Gerenciamento de Banco de Dados (SGBD)


Definição de SGBD

Um Sistema de Gerenciamento de Banco de Dados (SGBD) é um software desenvolvido para armazenar, administrar e consultar dados. Possui regras e critérios sobre como os dados serão inseridos, lidos, alterados e removidos.

Além disso são capazes de gerenciar as permissões de cada ação sobre os dados. Fazendo o elo entre o usuário que manipula os dados e o armazenamento físico.

DBMS: Database Management System
RDBMS: Relational Database Management System

Funcionamento de um SGBD



- Composto por um conjunto de módulos que constituem o banco de dados
- Gerencia o armazenamento físico dos dados
- Controla permissões de acessos e operações
- Interpreta e valida os comandos solicitados
- Controla as sessões de usuários
- Efetiva as operações de manipulação dos dados
- Demais interações com o Sistema Operacional (SO)

Tipos de bancos de dados



Relacionais

- São os tipos de banco de dados mais populares
- As tabelas se relacionam através de chaves primárias e chaves estrangeiras
- Possuem propriedade ACID (Atomicidade, Consistência, Isolamento e Durabilidade)
- Escalabilidade vertical

Not Only SQL

- Capazes de armazenar seus dados como objetos
- Gerenciam grandes volumes de dados
- Consistência eventual
- Alta disponibilidade
- Escalabilidade horizontal

ACID

+

+

- **Atomicidade** (Atomicity): Define que uma operação é executada com sucesso ou uma falha será apontada
- **Consistência** (Consistency): Regras que garantem o estado de um dado
- **Isolamento** (Isolation): Uma operação em andamento não é visível por outros usuários até que seja efetivada
- **Durabilidade** (Durability): Garante mudanças permanentes depois que uma transação é concluída

+

45697056

DB-Engines

DB-Engines is an initiative to collect and present information on database management systems (DBMS). In addition to established relational DBMS, systems and concepts of the growing NoSQL area are emphasized.

The [DB-Engines Ranking](#) is a list of DBMS ranked by their current popularity. The list is updated monthly.

The most important properties of numerous systems are shown in the overview of [database management systems](#). You can examine the properties for each system, and you can compare them side by side.

In the [database encyclopedia](#) terms and concepts on this topic are explained.

DB-Engines is maintained by [Redgate Software](#).

If you have suggestions, questions or general feedback, we would appreciate to get a [message](#) from you.

The latest news

[Are database management tasks slowing you down? Redgate Software wants to hear from you](#)
2 September 2024, Tim Dalton

[DB-Engines now owned by Redgate Software](#)
18 June 2024, Tom Russell

[PostgreSQL is the DBMS of the Year 2023](#)
2 January 2024, Matthias Gelbmann, Paul Andlinger

The most popular database management systems

October 2024	Score
1. Oracle	1309

Featured Products

 **RAIMA**
[RaimaDB](#), embedded database for mission-critical applications. When performance, footprint and reliability matters.
[Try RaimaDB for free.](#)



Vector database designed for GenAI, fully equipped for enterprise implementation.
[Try Managed Milvus for Free](#)


DATASTAX**ASTRA**

Bring all your data to [Generative AI](#) applications with [vector search](#)

DB-Engines Ranking

The DB-Engines Ranking ranks database management systems according to their popularity. The ranking is updated monthly.

Read more about the [method](#) of calculating the scores.



417 systems in ranking, February 2024

Rank			DBMS	Database Model	Score		
Feb 2024	Jan 2024	Feb 2023			Feb 2024	Jan 2024	Feb 2023
1.	1.	1.	Oracle +	Relational, Multi-model ⓘ	1241.45	-6.05	-6.08
2.	2.	2.	MySQL +	Relational, Multi-model ⓘ	1106.67	-16.79	-88.78
3.	3.	3.	Microsoft SQL Server +	Relational, Multi-model ⓘ	853.57	-23.03	-75.52
4.	4.	4.	PostgreSQL +	Relational, Multi-model ⓘ	629.41	-19.55	+12.90
5.	5.	5.	MongoDB +	Document, Multi-model ⓘ	420.36	+2.88	-32.41
6.	6.	6.	Redis +	Key-value, Multi-model ⓘ	160.71	+1.33	-13.12
7.	7.	↑ 8.	Elasticsearch	Search engine, Multi-model ⓘ	135.74	-0.33	-2.86
8.	8.	↓ 7.	IBM Db2	Relational, Multi-model ⓘ	132.23	-0.18	-10.74
9.	9.	↑ 12.	Snowflake +	Relational	127.45	+1.53	+11.80
10.	↑ 11.	↓ 9.	SQLite +	Relational	117.28	+2.08	-15.38
11.	↓ 10.	↓ 10.	Microsoft Access	Relational	113.17	-4.50	-17.86
12.	12.	↓ 11.	Cassandra +	Wide column, Multi-model ⓘ	109.27	-1.77	-6.95
13.	13.	13.	MariaDB +	Relational, Multi-model ⓘ	97.23	-2.00	+0.42
14.	14.	14.	Splunk	Search engine	91.65	-1.07	+4.57
15.	↑ 16.	15.	Amazon DynamoDB +	Multi-model ⓘ	82.90	+1.96	+3.21
16.	↓ 15.	16.	Microsoft Azure SQL Database	Relational, Multi-model ⓘ	79.56	-1.51	+0.81
17.	17.	↑ 19.	Databricks +	Multi-model ⓘ	76.91	-3.62	+16.58
18.	18.	↓ 17.	Hive	Relational	65.81	-1.15	-6.31
19.	19.	↑ 22.	Google BigQuery +	Relational	63.63	+0.15	+11.17
20.	20.	↓ 18.	Teradata	Relational, Multi-model ⓘ	51.24	-1.94	-11.79
21.	21.	21.	FileMaker	Relational	50.48	-1.56	-2.32
22.	22.	↓ 20.	Neo4j +	Graph	46.61	-1.57	-8.82
23.	23.	23.	SAP HANA +	Relational, Multi-model ⓘ	45.22	-1.22	-4.45
24.	24.	24.	Solr	Search engine, Multi-model ⓘ	44.60	-0.53	-1.28
25.	25.	25.	SAP Adaptive Server	Relational, Multi-model ⓘ	39.34	-0.09	-3.71
26.	26.	26.	HBase	Wide column	33.95	+0.09	-4.46
27.	27.	27.	Microsoft Azure Cosmos DB +	Multi-model ⓘ	31.99	-1.48	-4.52



É um ranking dos principais sistemas de gerenciamento de banco de dados ordenado por sua popularidade no mercado

Serve como uma referência e também para buscar mais informações sobre algum SGBD

Vale sempre consultá-lo para manter-se atualizado com relação ao que o mercado está usando e o que surge de novo.

Arquitetura de dados



Arquitetura de dados

A importância de uma arquitetura de dados reside em sua capacidade de fornecer uma **visão abrangente e organizada dos dados** de uma companhia, garantindo que os dados sejam **consistentes, precisos, seguros e acessíveis**.

Além disso, uma arquitetura de dados bem projetada pode facilitar a **integração de novas fontes de dados**, melhorar a **qualidade** dos dados, reduzir **custos e tempo** de desenvolvimento, e fornecer uma base sólida para **a análise e tomada de decisões**.

Aspectos importantes

Uma boa arquitetura de dados deve conter as seguintes referências para todos os dados da organização :

- ✓ **Modelagem de Dados**: taxonomia, formatos, nomes, chaves
- ✓ **Integração de Dados**: formatos, responsabilidades, monitoramento, criticidade
- ✓ **Segurança dos Dados**: tempo de vida, controle de acesso, confidencialidade
- ✓ **Qualidade dos Dados**: indicadores e linhagem dos dados
- ✓ **Armazenamento de Dados**: camadas de dados, categorização, governança
- ✓ **Processamento de Dados**: ferramentas de processamento, análise e visualização dos dados
- ✓ **Metadados**: catálogo, governança e disponibilização dos dados

45697056

Benefícios...

- ✓ **Consistência dos dados:** Uma arquitetura de dados bem projetada garante que os dados sejam consistentes e confiáveis em toda a organização, evitando discrepâncias e erros.
- ✓ **Melhoria da qualidade dos dados:** Ao estabelecer padrões e processos para a coleta e gestão de dados, uma arquitetura de dados ajuda a melhorar a qualidade geral dos dados da organização.
- ✓ **Facilitação da integração de dados:** Uma arquitetura de dados eficaz facilita a integração de dados de diferentes fontes e sistemas, permitindo uma visão mais completa e integrada das informações.
- ✓ **Suporte à tomada de decisões:** Uma arquitetura de dados bem projetada fornece uma base sólida para a análise de dados e tomada de decisões informadas, ajudando a melhorar o desempenho e a eficácia da organização.
- ✓ **Redução de custos e tempo de desenvolvimento:** Uma arquitetura de dados bem definida pode reduzir os custos e o tempo de desenvolvimento de novos projetos, ao fornecer uma estrutura clara e reutilizável para a gestão de dados.

Data Warehouse

A palavra "warehouse" em inglês significa "armazém" ou "depósito", um local onde produtos ou mercadorias são armazenados antes de serem distribuídos ou utilizados.

Um data warehouse tem um conceito semelhante ao de um armazém físico, mas aplicado ao contexto de dados. Assim como um armazém físico armazena e organiza produtos, um data warehouse armazena e organiza dados.

Surgimento do Data warehouse

Os Data warehouses surgiram com o crescimento de sistemas transacionais e volumes de dados gerados pelas empresas que trouxeram a necessidade de análises de dados mais robustas e que pudessem suportar decisões estratégicas de negócio.

Os sistemas transacionais (OLTP) não eram capazes de manter suas transações juntamente com o processamento de dados e geração de relatório (surgimento do mercado de BI)

45697056

Características

- Orientado a assunto de negócio



Diversos sistemas transacionais combinados fornecem os dados para compor o assunto “cliente”

- Dados não voláteis



Sua persistência e duração é permanente

- Integração



Combinação de diferentes dados integrados formam um dado de negócio

- Dados variam em função do tempo




Dados armazenados em formato de série temporal

Data Marts

Data Marts são conjuntos de dados criados para atender especificamente uma necessidade com um conjunto de dados reduzido (ex: consolidação diária de uma informação)


A combinação de Data Marts formam o Data Warehouse




Extract, Transform, Load (ETL)

ETL é a camada da arquitetura para extrair, transformar e carregar os dados no DW / DM.

- Modular e isolada para cada sistema fonte
- Suporta diferentes tecnologias para atender cada sistema fonte
- Atua na transformação e carga entre fontes de dados e consumos



Visão Geral



OLAP – Online Analytical Processing

OLAP (Online Analytical Processing) é uma abordagem de processamento de dados que permite aos usuários realizar consultas complexas e análises multidimensionais de grandes volumes de dados de maneira rápida e eficiente. OLAP é frequentemente utilizado em sistemas de Business Intelligence (BI) para analisar dados históricos, identificar tendências, fazer previsões e tomar decisões estratégicas.

Características do OLAP:

- **Análise Multidimensional:** Permite a visualização e análise de dados em múltiplas dimensões, como tempo, localização, produto, etc.
- **Velocidade e Eficiência:** Otimizado para consultas rápidas e complexas, proporcionando respostas quase instantâneas.
- **Operações OLAP:** Inclui operações como drill-down (exploração de dados em níveis mais detalhados), roll-up (resumo de dados em níveis mais agregados), slice and dice (filtragem e segmentação de dados) e pivot (reorientação das dimensões).

Exemplo Data Mart vs Warehouse

Caso de Uso: Análise de Vendas por Região para um Departamento de Marketing

Situação: Uma grande empresa de varejo possui um data warehouse centralizado que armazena todos os dados de vendas, estoque, clientes e fornecedores. O departamento de marketing da empresa deseja realizar uma análise detalhada das vendas por região para desenvolver estratégias de marketing específicas para diferentes áreas geográficas.




Desafios:

- O departamento de marketing precisa de acesso rápido e eficiente aos dados de vendas, especificamente filtrados por região.
- As consultas ao data warehouse central podem ser lentas e complexas devido ao grande volume de dados e à diversidade de informações armazenadas.

Solução com Data Mart: Para atender às necessidades específicas do departamento de marketing, a empresa decide criar um **data mart de vendas por região**. Este data mart é um subconjunto do data warehouse central e contém apenas os dados relevantes para a análise de vendas regionais, como:

- Informações de vendas (transações, produtos vendidos, valores)
- Dados de clientes (localização geográfica)
- Metadados relevantes (datas, promoções, campanhas)

Stack tecnológico DW

ETL	DATA BASES	ADVANCED ANALYTICS	DATA DISCOVERY OLAP
      	    	   	      

Evolução Data Warehouse


Fragilidades que surgiram nos DWs ao longo do tempo:

- Aumento no **volume de dados** com **mais dispositivos** conectados à internet
- Necessidade de análise de **dados sem estrutura** pré-definida
- **Alto custo** dos hardwares e software usados por ferramentas de DW
- Falta de **escalabilidade horizontal**
- Crescimento da necessidade de análise em **tempo real**, com escala global

Data Lake

Como surgiram os Data Lakes?

O barateamento de recursos computacionais como armazenamento e processamento da década de 70 até 2000, unificado ao processamento distribuído de dados, fez as empresas adotarem Data Lakes por serem alternativas mais baratas em relação aos Data Warehouses



45697056

Data Lake

- O que é um data lake?

É um repositório de dados centralizado capaz de armazenar, processar e disponibilizar grandes **volumes** de dados em seu formato **bruto e original (variedade)**, com grande **velocidade**. Estes dados podem ser estruturados, semiestruturados ou não estruturados. Isso inclui dados de sistemas transacionais, logs, redes sociais, sensores IoT, entre outros.

Os 3 V's - VOLUME

+

Data lakes, especialmente quando implementados em soluções de armazenamento em nuvem, como Amazon S3, Azure Data Lake ou Google Cloud Storage, oferecem uma opção de armazenamento de baixo custo em comparação com a infraestrutura de data warehouses. Isso permite que as empresas armazenem grandes volumes de dados de maneira mais econômica.

1 byte (B) = 8 bits
 1 kilobyte (KB) = 1.024 bytes
 1 megabyte (MB) = 1.024 kilobytes
 1 gigabyte (GB) = 1.024 megabytes
 1 terabyte (TB) = 1.024 gigabytes
 1 petabyte (PB) = 1.024 terabytes
 1 exabyte (EB) = 1.024 petabytes
 1 zettabyte (ZB) = 1.024 exabytes
 1 yottabyte (YB) = 1.024 zettabytes

1 byte é 1 caractere. Ex: a letra "A" ocupa 1 byte

2 elevado a ...	Em bytes	Nome
10	1.024	Kilobytes
20	1.048.576	Megabytes
30	1.073.741.824	Gigabytes
40	1.099.511.627.776	Terabytes
50	1.125.899.906.842.620	Petabytes
60	1.152.921.504.606.850.000	Exabytes
70	1.180.591.620.717.410.000.000	Zettabytes
80	1.208.925.819.614.630.000.000.000	Yotabytes

Volume de informações digitais estimada geradas pelo mundo em 2023 é de mais de **120 zettabytes**

Os 3 V's - Velocidade

Para muitos negócios atualmente, a capacidade de processamento, análise e tomada de decisão baseada em dados precisa acontecer em tempo real.

Data lakes são projetados para suportar altas taxas de entrada de dados, o que é essencial para cenários que demandam processamento e análise de dados em tempo real ou quase em tempo real, como monitoramento de redes sociais, análise de fluxo de cliques em e-commerce e processamento de dados de sensores IoT. A capacidade de lidar com grandes volumes de dados rapidamente permite que as empresas obtenham insights acionáveis de maneira oportuna e competitiva.

Os 3 V's - Variedade

A evolução de dispositivos e informações digitais trouxe o desafio de conseguir armazenar dados dos mais variados formatos. Data lakes se destacam por sua capacidade de armazenar e gerenciar uma ampla variedade de formatos de dados, incluindo tabelas de banco de dados, arquivos CSV, JSON, XML, logs de servidor, documentos de texto, imagens, vídeos, áudios, dados de sensores IoT e muito mais.

Essa versatilidade permite que as organizações centralizem todos os seus dados em um único repositório, independentemente do formato, facilitando a análise integrada e a extração de insights valiosos de fontes diversas. A capacidade de lidar com diferentes tipos de dados também torna os data lakes ideais para projetos de machine learning e inteligência artificial

Como implementar um Data Lake?

Existem diversas opções de soluções de Data Lake no mercado, mas uma das tecnologias mais utilizadas inclusive por parte dessas soluções é o **Hadoop**.

Hadoop é um framework de software de código aberto utilizado para o armazenamento e processamento de grandes volumes de dados em um ambiente distribuído. Há dois componentes fundamentais nessa plataforma:

- **Hadoop Distributed File System (HDFS):** Um sistema de arquivos distribuído que permite o armazenamento de dados em várias máquinas, proporcionando alta disponibilidade e tolerância a falhas. O HDFS divide os dados em blocos menores e os distribui através de um cluster de servidores, garantindo que mesmo se alguns nós falharem, os dados ainda estarão acessíveis.
- **MapReduce:** Um modelo de programação para processamento paralelo de grandes conjuntos de dados. O MapReduce divide as tarefas de processamento em duas etapas principais: Map (mapeamento) e Reduce (redução). Na etapa de Map, os dados são processados e transformados em pares chave-valor, enquanto na etapa de Reduce, os resultados são agregados e combinados para produzir a saída final.

Hadoop Distributed File System

HDFS

FIAP




<https://hadoop.apache.org/>

O HDFS surgiu em 2006 possibilitando processamento distribuído com um modelo de processamento para larga escala (Map Reduce)

Acelerou o desenvolvimento de novos produtos de dados para processamento e armazenamento baseados neste sistema de arquivos. **Ecosystema Hadoop.**

How Hadoop Works



- Armazenamento distribuído
- Processamento paralelo
- Particionamento de dados

Como o Hadoop se encaixa num contexto de Data Lakes e Arquitetura de Dados?

- Armazenamento Distribuído (HDFS): Hadoop HDFS é uma opção popular para o armazenamento de dados em data lakes devido à sua capacidade de lidar com grandes volumes de dados distribuídos em múltiplos servidores, garantindo alta disponibilidade e resiliência.
- Processamento de Dados (MapReduce, Spark): Hadoop permite o processamento paralelo e eficiente de grandes conjuntos de dados através do modelo MapReduce e da integração com Apache Spark, que oferece processamento em memória para análises rápidas.
- Flexibilidade e Integração: Hadoop integra-se bem com várias ferramentas e tecnologias de big data, como Hive para consultas SQL-like, Pig para scripts de processamento, e HBase para armazenamento de dados em tempo real. Essa flexibilidade permite que as empresas construam data lakes robustos e escaláveis.
- Implementação em Nuvem e On-Premises: Hadoop pode ser implementado tanto em infraestruturas on-premises quanto na nuvem, proporcionando uma solução versátil para diferentes cenários e necessidades empresariais.

Soluções de Data Lake em Cloud



- Amazon S3 (AWS): Oferece Amazon S3 para armazenamento de dados, AWS Glue para catalogação e ETL, e Amazon Athena para consultas ad-hoc em dados armazenados no S3.
- Microsoft Azure Data Lake Storage (ADLS): Fornece armazenamento escalável e seguro para grandes volumes de dados, integrado com Azure Synapse Analytics para análise de dados.
- Google Cloud Storage (GCS): Utilizado para armazenar dados, com integração com BigQuery para análise de dados e Dataflow para processamento.
- Hadoop em Nuvem: Implementar clusters Hadoop em infraestruturas de nuvem, como AWS (EMR), Azure (HDInsight) ou Google Cloud (Dataproc). Isso permite escalar rapidamente conforme a demanda e aproveitar os benefícios de ambas as abordagens.

Soluções de Data Lake on-Premises

- Hadoop: Usar Hadoop HDFS (Hadoop Distributed File System). Ferramentas como Apache Hive, Pig e Spark podem ser integradas para consultas e processamento de dados.
- Cloudera Data Platform (CDP): Uma plataforma de dados unificada que utiliza Hadoop e outras tecnologias de big data para criar e gerenciar data lakes on-premises ou na nuvem.
- Hortonworks Data Platform (HDP): Outra distribuição baseada em Hadoop que facilita a criação de data lakes on-premises, com ferramentas para ingestão, processamento e análise de dados.


O que é Map Reduce?

Estrutura de processamento distribuído de dados que pode ser utilizada para processar enormes quantidades de dados armazenados em HDFS.

Abstração de processamento distribuído, fornecendo paralelização automática dos programas e suporte gerenciado de tolerância a falhas.

Map

+



+


- Ponto de partida.
- Recebe cada registro dos dados de entrada como pares de chave/valor.
- Cada Mapper é independente um do outro, permitindo paralelismo e re-execuções de tarefas.
- Hadoop cria tarefas de Mapper para cada bloco de dados HDFS dos dados de entrada.
- Produz uma lista de chave/valor.

+

45697056

Reduce

+



+


- Responsável por agregações, filtros e combinações diversas nos dados de entrada.
- Executa uma função de reduce por vez.
- Shuffle: distribui as saídas dos mappers para a execução do reducer.
- Sort: ordena os registros chave/valor, agrupando pela chave.
- Reduce: envia os conjuntos chave/valor agrupados, filtrados ou combinados o formato de saída.

+

45697056

Exemplo

The overall MapReduce word count process



HDFS

- Tolerante a falhas.
- Escalável.
- Portabilidade.
- Processo vai aos dados.
- Projetado para arquivos muito grandes.
- Desenvolvido em Java.
- Coerência de dados (Escreva uma vez, leia muitos).
- Pode usar hardware commodity.
- Não projetado para baixa latência.
- Bloco de 128MB por padrão.
- **NameNode** e **DataNode**.
- Fator de replicação padrão igual 3.


Namenode

- Gerencia o sistemas de arquivos e regula acesso .
- Armazena metadados.
- Usa cache em RAM para acesso mais rápido ao metadado.
- Não armazena dados.
- Apenas 1 ativo por cluster.
- Ponto único de falha sem HA.
- HA no Haddop 2 com o NameNode em active-standby

Datanode

- Armazena os dados no HDFS.
- Atende solicitações de leitura e gravação dos clientes ou NameNode.
- Responsável por criar, excluir e replicar blocos de dados.
- Reporta status para o NameNode (heartbeat).
- Em caso de falta de report o nó é desativado pelo NameNode.
- Totalmente dependente do NameNode.

Arquitetura



O processamento é executado onde está o armazenamento

Caso de estudo em sala

Contexto: A "LojaMega", uma empresa de varejo online, tem um data warehouse que armazena dados de transações, inventário e informações de clientes. Eles usam esse data warehouse para gerar relatórios de vendas semanais, analisar o desempenho do inventário e acompanhar métricas de satisfação dos clientes.

- Configuração Atual: Data Warehouse: Contém tabelas de vendas, inventário, clientes e feedbacks, com dados estruturados e bem definidos.
- Relatórios: Relatórios de vendas semanais e mensais são gerados a partir do data warehouse.
- Consultas: Consultas analíticas sobre desempenho de produtos e níveis de estoque.

Nova Demanda: A LojaMega quer implementar uma nova estratégia de marketing personalizada e precisa analisar dados de comportamento dos usuários em tempo real, provenientes de várias fontes, incluindo redes sociais, logs de navegação no site e cliques em anúncios.

Questão: Quais são os aspectos que você considera mais relevantes na hora de desenhar uma solução para a demanda?

Hadoop – Distribuição de dados

O Hadoop executa 3 etapas para garantir a **distribuição** e **replicação** dos dados.

1ª etapa: Particionamento




45697056

Hadoop – Distribuição de dados

O Hadoop executa 3 etapas para garantir a **distribuição** e **replicação** dos dados.


2ª etapa: Distribuição dos dados



Hadoop – Distribuição de dados

O Hadoop executa 3 etapas para garantir a **distribuição** e **replicação** dos dados.

3ª etapa: Replicação dos dados



Distribuição de dados em nuvem

As clouds públicas têm sua infraestrutura global distribuída em regiões e zonas



Cada região possui 1 ou mais zonas de disponibilidade. Cada zona de disponibilidade corresponde a uma localidade onde a infraestrutura está localizada.

Distribuição de dados em nuvem

Exemplo Azure: Availability Zones


As “Availability Zones” no Azure são localizações físicas distintas dentro de uma região do Azure. Cada zona é composta por um ou mais datacenters com energia, refrigeração e rede independentes. Elas são projetadas para proteger suas aplicações e dados contra falhas de datacenter, aumentando disponibilidade e resiliência das soluções hospedadas.

Estão próximas o suficiente para terem conexões de baixa latência com outras zonas de disponibilidade. No entanto, estão suficientemente distantes umas das outras para reduzir a probabilidade de mais de uma ser afetada por interrupções locais ou condições climáticas.

Foram projetados para que, se uma zona sofrer uma interrupção, os serviços regionais, a capacidade e a alta disponibilidade sejam suportados pelas zonas restantes. Eles ajudam seus dados a permanecerem sincronizados e acessíveis quando algo dá errado.

Distribuição de dados em nuvem

A imagem abaixo traz uma visão esquemática representativa.



Amazon AWS: O conceito equivalente também é chamado de “Availability Zones” ou apenas “AZs”.


Google Cloud Platform (GCP): No GCP, o termo utilizado é simplesmente *Zones*. Cada região do GCP é composta por várias zonas, que são áreas de implantação com infraestrutura física distinta.

Distribuição de dados em nuvem

Custo e Segurança


Disponibilidade Local

Quando o dado ou infraestrutura está alocada em 1 zona e 1 região




Disponibilidade Regional

Quando o dado ou infraestrutura está alocada em mais de 1 zona e 1 região



Disponibilidade Global


Quando o dado ou infraestrutura está alocada em mais de 1 zona e mais de 1 região



Framework de dados



Framework de dados



Data Lakehouse


Data Warehouse + Data Lake = **Data Lakehouse**

Data Lakehouse

✓ • Data Warehouse

✓ • Data Lake

➔ • Data Lakehouse



- Transações ACID (Atomicity, Consistency, Isolation, Durability)
- Criação de relatórios para BI baseado em metadados pré-definidos
- Uso de dados não-estruturados e semi-estruturados
- Armazenamento barato
- Cargas de trabalho variadas para atendimento de Streaming
- Separação de armazenamento e processamento
- Rastreabilidade e linhagem dos dados

Processamento
elástico

Data Lakehouse

Considerações:

- Não necessariamente toda base de dados precisa usar essa estrutura.
- Apesar de endereçar *real-time* analytics, a performance não deve ser um pré-requisito primordial
- Resolve fraquezas tanto do Data Warehouse quanto do Data Lake, por suportar dados não estruturados e também conseguir tratar transações concorrentes.
- Oferece robustez e escalabilidade mantendo a precisão para o negócio
- É uma evolução natural a organização de Data Lakes


45697056

Data Lakehouse +


Data Warehouse




Data Lake



Data Lakehouse



Delta Lake



Delta Lake

Armazenamentos:

- Para conseguir garantir transações no uso do armazenamento o Delta Lake usa APIs nativas dos sistemas de armazenamentos (Log Store API) e implementa configurações específicas quando necessário (File System API).
- Os armazenamentos suportados são:
 - Amazon S3
 - Microsoft Azure storage
 - HDFS
 - Google Cloud Storage
 - Oracle Cloud Infrastructure
 - IBM Cloud Object Storage

Delta Lake


Melhores práticas:

- Escolha a coluna correta para particionamento
 - Não use uma coluna com muita granularidade. A coluna mais comum de se usar é a de *data*.
 - A recomendação é que cada partição tenha pelo menos 1 GB de dados.
- Compacte arquivos
 - Gravações pequenas e constante de dados podem gerar numerosos pequenos arquivos. Compacte-os em arquivos maiores a fim de obter melhor performance.
- Substituir conteúdo ou esquema de uma tabela pode ser feito através de uma operação de sobreposição para mudar um esquema, particionamento ou dados.
- Não use Spark Caching
 - A Databricks não recomenda o uso de Spark Caching pelo risco de perda de dados manipulados ou filtrados.

Apache Iceberg

Iceberg adiciona tabelas à ferramentas de processamento como Spark, Trino, PrestoDB, Flink, Hive e Impala, usando um formato de tabela de alta performance que funciona como uma tabela SQL

45697056



Apache Hudi




É uma plataforma de dados que traz capacidade de bancos de dados e data warehouse para um Data Lake, capaz de entregar processamentos robustos e analytics na casa de


minutos

Ref.: <https://hudi.apache.org/>

AWS Data Lakehouse



Google Data Lakehouse



Caso de estudo em sala

Contexto: A "LojaMega", uma empresa de varejo online, tem um data lake onde armazena dados de várias fontes, incluindo transações de vendas, inventário, interações com clientes, dados de redes sociais e logs de navegação no site.

Problema:

A LojaMega está enfrentando um problema crítico de inconsistência de dados entre as diferentes fontes armazenadas no data lake. As principais inconsistências incluem:

- 1.Dados de Vendas:** Os dados de transações de vendas do sistema de ponto de venda (POS) não correspondem aos dados de vendas registrados no sistema de e-commerce.
- 2.Dados de Inventário:** Há discrepâncias entre os níveis de estoque registrados no sistema de gerenciamento de inventário e os níveis de estoque relatados nas interações com clientes.
- 3.Dados de Clientes:** Informações de clientes coletadas por diferentes canais (loja física, site, redes sociais) não estão sincronizadas, resultando em perfis duplicados e informações conflitantes.

Questão: Quais são as possíveis opções que a empresa teria para resolver esses problemas? Levantem dois pontos pró e dois pontos contra cada opção para compararmos.

Data mesh

Dados e negócios orientados a domínios

Definição

Data Mesh é uma arquitetura descentralizada de dados focada em domínios de dados que facilitam a visão do dado como um produto de cada domínio. Esse modelo favorece a qualidade e acesso aos dados da companhia.

Em vez de centralizar todos os dados em um único repositório, como um data lake ou data warehouse, o Data Mesh propõe distribuir a responsabilidade pelo gerenciamento de dados entre várias equipes, baseando-se em domínios específicos

“Data Mesh is an analytical data architecture and operating model where data is treated as a product and owned by teams that most intimately know and consume the data” (*Zhamak Dehghani, 2019*)

Princípios

Propriedade sobre os domínios de dados

Encurtar a distância entre os consumidores de dados analíticos e os geradores de dados

Plataforma de dados self-service

Facilitar e automatizar o compartilhamento de dados pelos geradores e o acesso para os consumidores


Dados como produto

Produção de dados orientada para seus consumos

Governança federada

Políticas de dados globais e automatizadas que não centralizam responsabilidades sobre os dados

Arquitetura



Benefícios

- **Democratização de dados** facilitada através da arquitetura e plataforma self-service
- **Eficiência Financeira** através da adoção de plataformas em cloud que dão melhor visão financeira para reduzir ineficiências
- **Menos débitos técnicos** devido a aproximação dos times que geram dados com os times que os consomem
- **Interoperabilidade** através da governança e padronização sobre os dados
- **Segurança e conformidade** por usar padrões de dados independentes de domínio, dando observabilidade e rastreabilidade.


Vantagens

- **Escalabilidade:** Descentralizando a gestão de dados, permite que múltiplas equipes trabalhem simultaneamente em seus próprios domínios, sem sobrecarregar um time centralizado.
- **Governança distribuída:** As equipes responsáveis pelos domínios têm mais controle sobre a qualidade e a segurança dos dados.
- **Agilidade:** Facilita a entrega rápida de soluções de dados, já que cada equipe tem autonomia sobre seu ambiente de dados.
- **Adoção mais fácil de novas tecnologias:** Permite que cada domínio adote ferramentas e tecnologias adequadas às suas necessidades.


Desvantagens

- **Complexidade operacional:** Implementar um Data Mesh requer uma mudança significativa de mentalidade e organização, o que pode ser desafiador para empresas que estão acostumadas a arquiteturas centralizadas.
- **Custos iniciais altos:** O desenvolvimento de infraestrutura para suportar uma plataforma de autoatendimento pode exigir um investimento significativo.
- **Governança e conformidade descentralizada:** Embora haja benefícios, também há riscos na descentralização da governança de dados, o que pode levar à falta de padronização e possíveis problemas de conformidade.

Arquitetura de Dados Netflix




Arquitetura de Dados Uber



Não é uma arquitetura de dados

Conceptual Data Diagram


A conceptual data diagram for a simple order manager involved in the process, such as customers, orders, products, and invoices. Entities are related at a high level without going into attribute details. This type of diagram helps stakeholders understand the overall system, making it easier to discuss and plan further development.



Source: [Vertabelo](#)

Logical Data Diagram


A logical data diagram for an order management system breaks down the main entities into detailed components, such as customer IDs, order numbers, product details, and invoice information. It highlights the attributes, relationships, and constraints between entities, providing a clear blueprint for database design. This diagram helps in understanding the logically structured data and ensures all necessary data elements are considered in the development phase.



Source: [TIBCO](#)


Physical Data Diagram

A physical data diagram for an order management system maps out the actual data storage locations, columns, indexes, and relationships used to store and manage data. It includes details such as storage locations, data types, and constraints. This diagram is useful for database administrators as it guides the technical implementation and optimization of the data storage architecture.



Source: [Visual Paradigm](#)




MBA⁺

Copyright © 2025 Prof. Leandro Mendes

Creditos:

Prof Jorge Surian

Prof Ivan Gancev

Prof Marcelo Manzano

Todos direitos reservados. Reprodução ou divulgação total ou parcial deste documento é expressamente proibido sem o consentimento formal, por escrito, do Professor Ivan Gancev
profivan.gancev@fiap.com.br

