

MBA AI ENGINEERING & MULTI-AGENTS • MÓDULO AI AGENTS

Generative Models

AULA 1

Representações de texto em modelos de linguagem

Da contagem de palavras ao modelo usado por instrução

prof. Thiago Nascimento Nogueira

e-mail: profthiago.nogueira@fiap.com.br

linkedin: <https://www.linkedin.com/in/thnogueira/>

Se o modelo já vem treinado, o que resta construir no sistema?

Esta disciplina responde a essa pergunta em seis noites.

Construção do classificador e uso de modelo pré-treinado

A tarefa é classificar uma mensagem de cliente por assunto. As duas colunas comparam os dois caminhos para construir o classificador.

Treinar um modelo para a tarefa

O QUE É PRECISO TER

um conjunto de mensagens já rotuladas por assunto

O QUE É PRECISO TREINAR

uma representação do texto e um classificador

O QUE O RESULTADO RESOLVE

só essa tarefa

Usar um modelo pré-treinado

O QUE É PRECISO TER

uma frase que descreve a tarefa

O QUE É PRECISO TREINAR

nada

O QUE O RESULTADO RESOLVE

essa tarefa e outras, descritas por outra frase

A tarefa é a mesma nas duas colunas. O que muda é o que cada caminho exige para construir o sistema.

Mapa da disciplina

1

Representações de texto em modelos de linguagem

Da contagem de palavras ao Transformer, e a introdução aos modelos de linguagem

hoje

2

Modelos grandes e modelos pequenos

Critério de escolha entre LLM e SLM, e a construção do prompt

3

Adaptar um modelo ao domínio

Fine-tuning completo e eficiente em parâmetros, com LoRA e QLoRA

4

Reduzir e medir

Redução do tamanho e do custo de um modelo, e medição da qualidade da resposta

5

Modelos multimodais

Visão, áudio e modelos de difusão para geração de imagem

6

Casos de uso e projeto integrado

O caso Quantum Commerce, de ponta a ponta

Roteiro da noite

O PROBLEMA

1

Conversão de texto em número

o modelo calcula sobre vetores, e a entrada é uma frase

2

Significado a partir do contexto

duas frases de mesmo sentido sem palavra em comum recebem similaridade zero

3

Representação contextual

o vetor de uma palavra é o mesmo em qualquer frase

4

Do Transformer ao modelo pré-treinado

cada tarefa exige um conjunto rotulado e um treino próprios

A TÉCNICA

contagem de palavras, ponderada pela raridade do termo no conjunto

um vetor por palavra, aprendido a partir das palavras vizinhas

self-attention, que recalcula o vetor de cada palavra a partir das outras palavras da frase

um modelo pré-treinado, que executa a tarefa a partir de uma instrução escrita

01

Conversão de texto em número

Um modelo de linguagem calcula sobre vetores numéricos. O primeiro passo de qualquer sistema de linguagem é representar a frase como um vetor de números.

Dificuldades de representação de texto

Dimensão

Uma representação com uma posição por palavra do vocabulário produz um vetor com tantas posições quantas palavras há no vocabulário, e quase todas valem zero em cada documento.

Significado

Duas frases podem ter o mesmo sentido sem nenhuma palavra em comum, e duas palavras de grafia parecida podem ter sentidos sem relação.

Ambiguidade

A mesma palavra tem sentidos diferentes conforme a frase em que ocorre, e uma representação fixa por palavra atribui o mesmo vetor a todos eles.

As três são propriedades da língua, e cada uma impõe um requisito à representação.

Bag of words

Bag of words (saco de palavras) representa um documento por um vetor com uma posição para cada palavra do vocabulário, e em cada posição a contagem de vezes que a palavra ocorre no documento. O documento passa a ser um ponto num espaço numérico.

DUAS MENSAGENS E O VETOR DE CADA UMA. O VOCABULÁRIO É O CONJUNTO DAS PALAVRAS DISTINTAS DAS DUAS, EM ORDEM ALFABÉTICA

MENSAGEM	a	clique	confirmo	e	ganhe	levo	link	no	o	prêmio	relatório	reunião
spam <i>Clique no link e ganhe o prêmio.</i>	0	1	0	1	1	0	1	1	1	1	0	0
normal <i>Confirmo a reunião e levo o relatório.</i>	1	0	1	1	0	1	0	0	1	0	1	1

Toda palavra do texto entra no vocabulário, inclusive a, e, no e o. A contagem não escolhe palavra.

As duas mensagens coincidem em duas posições, e e o, e diferem nas outras dez. É nessas dez que o classificador se apoia.

Tamanho fixo

o vetor tem uma posição por palavra do vocabulário, qualquer que seja o tamanho do documento

Decisão explicável

cada posição tem o nome de uma palavra, e o peso que o classificador atribui a ela é lido direto

Custo de uma passada

a representação é uma contagem, calculada numa leitura do texto, sem treino de representação e sem GPU

A contagem resolve a tarefa em que a decisão depende de quais palavras ocorrem no documento.

Demonstração 1, filtro de spam por contagem de palavras

AO VIVO

O QUE RODA

Mensagens de SMS reais, em português, marcadas como spam ou normal. A contagem de palavras é a entrada de um classificador Naive Bayes, avaliado por validação cruzada.

O QUE OBSERVAR

A acurácia do classificador na validação cruzada, e as mensagens classificadas errado. A mensagem errada mostra em quais palavras a classificação se apoiou.

O classificador usa só a contagem de palavras, sem nenhuma informação sobre o sentido delas.

Identificação dos termos mais relevantes

Na contagem, todas as palavras têm o mesmo peso. As palavras que ocorrem em quase todo documento recebem os maiores valores e são as que mais pesam na comparação entre documentos.

O QUE A CONTAGEM PRODUZ

PALAVRA	OCORRÊNCIA NO CORPUS	VALOR NO VETOR	PODER DE DISTINÇÃO
<i>o, de, que, para</i>	ocorrem em quase todo documento de qualquer corpus	contagem alta	não distingue um documento de outro
<i>conta, cliente, atendimento</i>	ocorrem em quase toda mensagem de um corpus de atendimento bancário	contagem alta	não distingue um documento de outro
<i>empréstimo, saldo</i>	ocorrem em poucas mensagens	contagem baixa	distingue as mensagens em que ocorre

O ajuste consiste em ponderar cada contagem pela raridade da palavra no conjunto de documentos, e é isso que o TF-IDF faz.

Uma lista de stop words (palavras removidas antes da contagem) elimina a primeira linha e mantém a segunda, que tem o mesmo efeito sobre a comparação.

Matriz documento-termo

A matriz documento-termo reúne os vetores de um conjunto de documentos, um por linha, com uma coluna por palavra do vocabulário. A ordem das palavras dentro do documento fica de fora, e o que resta é a contagem.

TRÊS FRASES E A MATRIZ DE CONTAGEM

DOCUMENTO	atendeu	cliente	empréstimo	gerente	o	pediu	saldo	um
f1 o cliente pediu um empréstimo	0	1	1	0	1	1	0	1
f2 o cliente pediu o saldo	0	1	0	0	2	1	1	0
f3 o gerente atendeu o cliente	1	1	0	1	2	0	0	0

A coluna de o tem a maior soma das três, e é a coluna que menos separa uma frase da outra.

A coluna de empréstimo ocorre em uma frase só, e é a que mais separa.

Num vocabulário real cada linha usa uma fração pequena das colunas, e é essa matriz que o TF-IDF pondera a seguir.

Estas três frases são o conjunto de documentos com que o idf é calculado a seguir.

TF-IDF

TF-IDF (term frequency, inverse document frequency) multiplica a frequência do termo no documento, *tf*, pela frequência inversa de documento, *idf*, que decresce com o número de documentos do conjunto em que o termo ocorre. Termo presente em todo documento recebe peso zero.

A FÓRMULA

$$\text{tfidf}(t, d) = \text{tf}(t, d) \times \text{idf}(t)$$

$$\text{idf}(t) = \ln(N / \text{df}(t))$$

N documentos no conjunto, *df*(*t*) documentos que contêm *t*

O IDF DAS TRÊS FRASES ANTERIORES

<i>o</i>	3 de 3	$\ln(3/3) = 0$
<i>cliente</i>	3 de 3	$\ln(3/3) = 0$
<i>empréstimo</i>	1 de 3	$\ln(3/1) = 1,10$

Com as três frases do slide anterior, *o* e *cliente* ocorrem em todos os documentos e recebem peso zero. *Empréstimo* ocorre em um documento só e recebe o maior *idf* da tabela.

A implementação do scikit-learn usa a variante suavizada $\text{idf}(t) = \ln((1+N)/(1+\text{df}(t))) + 1$, que evita divisão por zero e não zera o peso de nenhum termo.

A contagem registra quantas vezes o termo ocorre no documento. O *idf* registra em quantos documentos do conjunto ele ocorre.

Similaridade de cosseno

Com documentos representados por vetores, a proximidade entre dois documentos é medida pelo cosseno do ângulo entre eles. O cosseno depende da direção dos vetores e não do comprimento, e por isso um documento longo e um curto sobre o mesmo assunto ficam próximos.

$$\cos(a, b) = \frac{a \cdot b}{\|a\| \|b\|}$$

EXEMPLO TRABALHADO, VOCABULÁRIO DE TRÊS PALAVRAS

$a = (1, 1, 0)$ documento com as palavras 1 e 2

$b = (1, 0, 1)$ documento com as palavras 1 e 3

$a \cdot b = 1 \times 1 + 1 \times 0 + 0 \times 1 = 1$ só a primeira palavra é comum aos dois


$\|a\| = \|b\| = \text{raiz de } 2$ cada vetor tem duas posições iguais a 1

$\cos(a, b) = 1 / 2 = 0,5$ ângulo de 60 graus entre os dois

O resultado fica entre 0 e 1 para vetores de contagem, porque nenhuma posição é negativa. O valor 1 indica a mesma direção, e o valor 0 indica nenhuma palavra em comum.

A CONSTRUÇÃO DO COSSENO

$$a \cdot b = \|a\| \cdot \|b\| \cdot \cos \theta$$



A projeção da ponta de a sobre a direção de b mede $\|a\| \cdot \cos \theta$. Aqui ela vale metade de $\|a\|$, e é essa razão que o cosseno 0,5 registra.

A similaridade de cosseno mede o ângulo entre os dois vetores, e o comprimento de cada vetor não entra na medida.

Demonstração 2, recuperação da passagem que responde à pergunta

AO VIVO

O QUE RODA

Um conjunto de trechos sobre assuntos distintos e uma pergunta. Os dois são representados como vetores TF-IDF, e os trechos são ordenados pelo cosseno com a pergunta. É o passo de recuperação de um RAG (retrieval-augmented generation, geração com contexto recuperado).

O QUE OBSERVAR

A fração das perguntas em que o trecho correto fica em primeiro lugar, e a posição do trecho correto quando a pergunta tem palavras em comum com um trecho de outro assunto.

A ordenação dos trechos por similaridade de cosseno com a pergunta é a operação de busca de um sistema de recuperação.

Limites da contagem de palavras

TF-IDF compara documentos pelas palavras que eles têm em comum. Quando duas frases têm o mesmo sentido e nenhuma palavra em comum, o produto escalar dos dois vetores é zero, e a similaridade também.

Mesmo assunto, nenhuma palavra em comum

“O cliente foi ao banco pedir um empréstimo.”

“Aquela correntista solicitou financiamento.”

similaridade zero

Assuntos diferentes, uma palavra em comum

“O cliente foi ao banco pedir um empréstimo.”

“Ele sentou no banco da praça.”

similaridade acima de zero

No segundo par, a palavra em comum é banco, com um sentido em cada frase. Pela similaridade de cosseno, a frase sobre o banco da praça fica mais perto da primeira frase do que a frase de mesmo sentido.

02

Significado a partir do contexto

A contagem de palavras compara documentos pelas palavras que eles têm em comum. Um vetor aprendido a partir das palavras vizinhas representa cada palavra pelo contexto em que ela ocorre.

Hipótese distribucional

abalroar

O que significa?

O motorista **abalroou** o **poste** na saída da **garagem**.

Abalroei o **carro** da frente quando o **semáforo** fechou.

O **caminhão abalroou** a **mureta** da via expressa.

As três frases não trazem a definição de abalroar. O sentido de colisão é inferido das palavras ao redor: motorista, poste, garagem, carro, semáforo, caminhão, mureta e via.

Harris (1954) propõe a hipótese distribucional: o significado de uma palavra se manifesta na distribuição das palavras que ocorrem ao redor dela. As palavras vizinhas de abalroar nas três frases são as mesmas que ocorrem ao redor de bater e de colidir.


Se o significado se manifesta na vizinhança, a representação de uma palavra pode ser aprendida a partir das palavras vizinhas.

CBOW

CBOW (continuous bag of words) é uma das duas arquiteturas do word2vec (Mikolov et al., 2013). As quatro vizinhas entram juntas, e a rede é treinada para prever a palavra central.

O gerente atendeu o **cliente** na agência hoje.

AS QUATRO VIZINHAS E A ENTRADA DA REDE



A SAÍDA, UMA PROBABILIDADE POR PALAVRA DO VOCABULÁRIO



Cada vizinha entra como um vetor com uma posição por palavra do vocabulário, com 1 na posição dela e 0 nas demais.

A camada oculta recebe a média dos vetores das quatro vizinhas, e a ordem delas não altera essa média. Daí o nome bag of words.

A saída atribui uma probabilidade a cada palavra do vocabulário, e o erro na palavra central ajusta os vetores das quatro vizinhas.


o vetor de cliente, aprendido no treino

Skip-gram

Skip-gram é a outra arquitetura do word2vec e inverte o desenho anterior. A palavra central entra sozinha, e a rede é treinada para prever as quatro vizinhas.

O gerente **atendeu** o **cliente** na agência hoje.

A PALAVRA CENTRAL E A ENTRADA DA REDE



o vetor de cliente, aprendido no treino

A SAÍDA, UMA PROBABILIDADE POR PALAVRA DO VOCABULÁRIO

A palavra entra como um vetor com uma posição por palavra do vocabulário, com 1 na posição dela e 0 nas demais (codificação one-hot).

A camada oculta tem a dimensão do vetor aprendido, e a ativação dela é a linha da tabela de vetores que corresponde a essa palavra.

A saída dá uma probabilidade para cada palavra do vocabulário, e o erro nas quatro vizinhas ajusta essa linha, uma frase de cada vez.

02 • SIGNIFICADO A PARTIR DO CONTEXTO

Proximidade entre palavras diferentes

Cada ocorrência de uma palavra gera uma amostra de treino, com as vizinhas como entrada e a palavra central como alvo.

QUATRO FRASES DO CORPUS

*o gerente atendeu o **cliente** na agência*

*o gerente atendeu o **correntista** na agência*

*ontem o **cliente** pediu empréstimo*

*ontem o **correntista** pediu financiamento*

AS AMOSTRAS DE TREINO EXTRAÍDAS DELAS

AMOSTRA	ENTRADA, AS QUATRO VIZINHAS	ALVO, A PALAVRA CENTRAL
1	atendeu, o, na, agência	cliente
2	atendeu, o, na, agência	correntista
3	ontem, o, pediu, empréstimo	cliente
4	ontem, o, pediu, financiamento	correntista

As amostras 1 e 2 têm a mesma entrada e alvos diferentes. O treino aproxima os vetores de cliente e de correntista, porque as duas palavras são previstas a partir das mesmas vizinhas.

Demonstração 3, comparação entre TF-IDF e embeddings

AO VIVO

O QUE RODA

Três frases. Duas têm o mesmo sentido e nenhuma palavra em comum, e a terceira trata de outro assunto e tem uma palavra em comum com a primeira. As três são comparadas por TF-IDF e por embeddings, os vetores de palavra aprendidos a partir de um corpus em português.

O QUE OBSERVAR

A ordem das outras duas frases em relação à primeira, em cada uma das duas representações.

A similaridade por TF-IDF depende das palavras em comum. A similaridade por embeddings depende dos contextos em que as palavras ocorrem no corpus de treino.

Vetor único por palavra

O treino produz uma tabela de vetores, com um vetor por palavra do vocabulário. A consulta a essa tabela não depende da frase em que a palavra ocorre.

Sentado no **banco** da praça, ele leu que o **banco** fechou mil agências.

As duas ocorrências recebem o mesmo vetor, porque a tabela tem uma linha para banco e nenhuma informação sobre a frase em que a palavra ocorre.

O que o embedding registra

o contexto médio em que a palavra ocorre no corpus inteiro
a proximidade com palavras que ocorrem em contextos parecidos

O que ele não registra

qual dos sentidos está em uso numa frase dada
a ordem das palavras da frase e a relação entre elas

O vetor da tabela depende só da palavra, e não da frase em que ela ocorre.


03

Representação contextual

Na tabela de vetores, uma palavra tem o mesmo vetor em qualquer frase. A representação contextual recalcula o vetor de cada palavra a partir das outras palavras da mesma frase.

Arquitetura do Transformer

Vaswani et al. (2017) propõem o Transformer, arquitetura que processa sequências só com mecanismos de atenção, sem recorrência e sem convolução. Todas as posições da frase são processadas em paralelo, e a relação entre elas é calculada pela self-attention.



Conexões residuais e normalização de camada omitidas no desenho.

O bloco que se repete

Cada bloco aplica vários mecanismos de self-attention em paralelo, os attention heads (cabeças de atenção), que recalculam o vetor de cada posição a partir das outras, e uma rede densa, aplicada a cada posição separadamente. O modelo empilha N blocos, e o BERT-base e o GPT-2 pequeno têm 12 (Devlin et al., 2019, e Radford et al., 2019).

A ordem das palavras

A self-attention não usa a posição das palavras. Sem a codificação de posição somada ao vetor de entrada, duas frases com as mesmas palavras em ordens diferentes produzem os mesmos vetores.

Codificador e decodificador

O artigo original tem um codificador (encoder), que processa a frase de entrada inteira, e um decodificador (decoder), que gera a saída uma palavra por vez. O BERT usa só o codificador, e o GPT só o decodificador.

A self-attention relaciona duas posições quaisquer da frase em uma operação, sem percorrer as posições intermediárias.

Média ponderada por pesos de self-attention

Self-attention (atenção de uma frase sobre ela mesma) recalcula o vetor de cada palavra como a média ponderada dos vetores de todas as palavras da frase. Os pesos são calculados a partir da própria frase e somam 1, e cada ocorrência da palavra recebe um conjunto de pesos próprio.

Sentado	no	banco ¹	da	praça	ele	leu	que	o	banco ²	fechou	mil	agências
---------	----	--------------------	----	-------	-----	-----	-----	---	--------------------	--------	-----	----------

PESO DE CADA PALAVRA NA PRIMEIRA OCORRÊNCIA DE BANCO

Alturas de exemplo, criadas para a explicação. Cada linha soma 1.



PESO DE CADA PALAVRA NA SEGUNDA OCORRÊNCIA DE BANCO



A primeira ocorrência concentra peso em praça e em sentado, as palavras que fixam o sentido de assento. A segunda concentra peso em agências e em fechou. As duas saídas são médias dos mesmos vetores com pesos diferentes, e por isso são dois vetores distintos para a mesma palavra.

O vetor de banco deixa de ser uma linha fixa da tabela de vetores e passa a ser calculado em cada frase, a partir das palavras dela.

Cálculo da atenção de uma palavra

O exemplo usa três palavras da frase, com vetores de quatro posições criados para a explicação. Na conta abaixo x é o vetor de banco, x_i é o de cada uma das três palavras, inclusive banco, e d_k é a dimensão, 4 neste exemplo.

OS VETORES DE ENTRADA

banco	1	0	1	0
da	0	1	0	0
praça	0	0	1	1

Sentado no **banco** da praça

A CONTA PARA A LINHA DE BANCO, COM i PERCORRENDO AS TRÊS PALAVRAS

O PASSO	$i = \text{banco}$	$i = \text{da}$	$i = \text{praça}$
$S_i = x \cdot x_i$	$1 \cdot 1 + 0 \cdot 0 + 1 \cdot 1 + 0 \cdot 0 = 2,0$	$0,0$	$1,0$
$s_i / \sqrt{d_k}$	$2,0 / 2 = 1,0$	$0,0$	$0,5$
$\alpha_i = e^{s_i / \sqrt{d_k}} / \sum_j e^{s_j / \sqrt{d_k}}$	$e^{1,0} / (e^{1,0} + e^{0,0} + e^{0,5}) = 0,51$	$0,19$	$0,31$
$z = \sum_i \alpha_i x_i$	$0,51 \cdot [1 \ 0 \ 1 \ 0] + 0,19 \cdot [0 \ 1 \ 0 \ 0] + 0,31 \cdot [0 \ 0 \ 1 \ 1] = [0,51 \ 0,19 \ 0,82 \ 0,31]$		

Os três pesos somam 1. A quarta posição da saída, 0,31, vem inteira de praça, porque banco e da têm 0 nessa posição.

A representação de banco nesta frase passa de $[1 \ 0 \ 1 \ 0]$ para $[0,51 \ 0,19 \ 0,82 \ 0,31]$, porque da e praça entraram na média com pesos 0,19 e 0,31.

Consulta, chave e valor

Na conta anterior, o mesmo vetor de cada palavra cumpriu três papéis. No Transformer, cada papel recebe uma projeção própria, calculada por uma matriz aprendida no treino, e o artigo original dá um nome a cada papel.

O PAPEL NA CONTA ANTERIOR	O NOME	A PROJEÇÃO
o vetor de banco, comparado com o de cada palavra	Consulta (query)	$Q = X \cdot W_q$
o vetor de cada palavra, com que a consulta é comparada	Chave (key)	$K = X \cdot W_k$
o vetor de cada palavra, que entra na soma ponderada	Valor (value)	$V = X \cdot W_v$

$$\text{Attention}(Q, K, V) = \text{softmax}\left(\frac{QK^T}{\sqrt{d_k}}\right)V$$


X é a matriz com o vetor de cada palavra da frase, uma por linha. dk é a dimensão da chave, 4 no exemplo anterior e 64 por head no BERT-base (Devlin et al., 2019). A divisão pela raiz de dk mantém os produtos escalares numa faixa em que o softmax não satura.

Assimetria entre consulta e chave
Com um vetor só, o produto escalar é simétrico, e na conta anterior o de banco com praça vale 1,0 nos dois sentidos. Com Wq diferente de Wk, o peso de praça na linha de banco difere do peso de banco na linha de praça.

Todas as palavras da frase entram na soma ponderada, cada uma com o peso calculado pelo softmax.

Mecanismos de atenção em paralelo

O cálculo anterior é repetido h vezes em paralelo, cada vez com um trio de matrizes próprio. Cada repetição é um attention head e produz o seu próprio conjunto de pesos para cada palavra. As saídas são concatenadas e projetadas de volta à dimensão original por uma matriz W_o .



Alturas de exemplo, criadas para a explicação. Cada head produz um conjunto de pesos próprio para a mesma palavra, e cada conjunto soma 1.

Função de vários heads

Um head produz um único conjunto de pesos por palavra, e todas as relações da frase teriam de caber nele.

Com vários heads, cada um pode codificar uma relação diferente, e a saída da palavra concatena todas.

O BERT-base tem 12 camadas com 12 attention heads cada, 144 mapas de self-attention por frase, com d_k igual a 64 em cada head (Devlin et al., 2019).

Cada head produz um conjunto de pesos por palavra, e no BERT-base uma palavra recebe 144 conjuntos de pesos por frase.

Demonstração 4, extração dos pesos de self-attention no BERT

AO VIVO

O QUE RODA

Primeiro, no navegador, o Transformer Explainer, que roda um GPT-2 pequeno em inglês e mostra na mesma tela os tokens (as unidades em que o modelo divide o texto), o mapa de self-attention de cada head e a probabilidade da próxima palavra. Entram duas frases com a palavra bank em sentidos diferentes.

Depois, no notebook, um BERT em português (BERTimbau, Souza et al., 2020) recebe uma frase em que um pronome se refere a um substantivo anterior. Os pesos de self-attention são extraídos camada por camada e head por head, e medidos entre o pronome e os dois substantivos candidatos a antecedente.

O QUE OBSERVAR

No navegador, a distribuição de probabilidade da próxima palavra e o mapa de cada head, antes e depois da troca de uma palavra da frase. O mapa do GPT-2 é triangular porque cada posição usa só as posições anteriores, e o BERT do notebook usa as duas direções.

No notebook, quantas das 144 combinações de camada e head dão ao pronome um peso maior no candidato correto, e qual é a diferença de peso entre os dois candidatos no head em que ela é maior.

A medição percorre as 12 camadas e os 12 heads do BERT, um mapa de self-attention por vez.

Medição por camada e por attention head

A afirmação intuitiva é que a self-attention resolve a referência de um pronome ao antecedente. A medição da demonstração sustenta três afirmações mais precisas.

1

Diluição da relação na média dos heads

Na média dos 144 heads, o peso entre o pronome e o antecedente se dilui entre heads que codificam outras relações da frase.

2

Concentração de atenção nos tokens [CLS] e [SEP]

Os tokens de início e de separação, [CLS] e [SEP], recebem peso alto em muitos heads. Clark et al. (2019) medem que mais da metade da atenção das camadas 6 a 10 do BERT-base em inglês vai para [SEP].

3

Localização da relação em heads específicos

Em pelo menos um head, o peso do pronome no candidato correto supera o peso no candidato errado, e é esse head que sustenta a afirmação. A posição desse head é encontrada por medição, e a arquitetura não a determina.

A representação contextual de uma palavra depende da frase, e a relação com outra palavra fica registrada em heads específicos.

Especialização dos attention heads

A medição de uma frase localiza um head. Clark et al. (2019) medem, no BERT-base em inglês, heads que codificam relações sintáticas definidas e heads que direcionam a atenção a [SEP] quando a relação deles não se aplica.

HEAD	RELAÇÃO CODIFICADA	ACERTO DO HEAD	ACERTO DA REGRA SIMPLES
8-10	objeto direto do verbo	86,8%	40,0%
8-11	determinante do substantivo	94,3%	51,7%
5-4	antecedente de um pronome	65%	52%

Clark et al. (2019), tabelas 1 e 2, com o BERT-base em inglês. A regra simples é, nas duas primeiras linhas, o melhor deslocamento fixo de posição, e, na terceira, a coincidência da palavra principal entre pronome e candidato. Na mesma tabela, um sistema de correferência baseado em regras chega a 69%.

Atenção direcionada a [SEP]

Mais da metade da atenção das camadas 6 a 10 vai para o token [SEP]. No head 8-10, que codifica o objeto direto, as posições a que a relação não se aplica direcionam a atenção para [SEP]. Os autores interpretam isso como operação nula, em que o head descarta a atenção quando a relação dele não se aplica. Kovaleva et al. (2019) classificam os mapas de atenção em cinco padrões, e o padrão vertical, de atenção a [CLS] e [SEP], cobre 30% da amostra anotada.

Uma relação entre palavras fica codificada em attention heads específicos, e a média de todos os heads dilui o peso de cada um.

04

Do Transformer ao modelo pré-treinado

As técnicas anteriores exigem um treino próprio, e o classificador exige um conjunto rotulado por tarefa. Um modelo pré-treinado por terceiros executa a tarefa a partir de uma instrução escrita em português.

Geração de texto

Um modelo de linguagem atribui uma probabilidade a cada palavra candidata a próxima, dado o texto anterior. O treino usa texto corrido sem anotação humana, porque o alvo de cada passo é a palavra seguinte do próprio texto.

O gerente atendeu o cliente na ?

agência

fila

segunda

praça

Alturas de exemplo, criadas para a explicação.

O decodificador gera uma palavra por vez

a palavra gerada é acrescentada à entrada, e o cálculo se repete para a seguinte

A self-attention usa só as posições anteriores

durante a geração, cada posição usa apenas as palavras anteriores a ela, porque as seguintes ainda não existem no momento do cálculo

Escala e capacidade

o mesmo objetivo de treino, com mais dados e mais parâmetros, produz capacidades que o modelo menor não tem, como Brown et al. (2020) documentam

O pré-treino tem um único objetivo, prever a próxima palavra, e não usa rótulo humano.

Tokenização do texto

Um token é a unidade em que o modelo divide o texto antes de calcular. O vocabulário do modelo é a lista fechada de tokens, e toda entrada e toda saída são sequências de índices dessa lista. O tamanho da janela de contexto e o preço de cada chamada são contados em tokens.

A MESMA FRASE EM TRÊS TOKENIZADORES, “O correntista solicitou o financiamento imobiliário.”

MODELO E ALGORITMO	VOCABULÁRIO	TOKENS	AS PEÇAS
BERTimbau, WordPiece	29.794	10	0 · corre · ##ntis · ##ta · solicitou · o · financiamento · imobil · ##iário · .
GPT-4, BPE cl100k	100.277	14	0 · cor · rent · ista · solicit · ou · o · financ · i · amento · im · obili · ário · .
GPT-4o, BPE o200k	200.019	11	0 · corr · ent · ista · solicit · ou · o · financiamento · imobili · ário · .

Tamanhos de vocabulário lidos na configuração pública de cada modelo e na biblioteca tiktoken. As peças saíram dos próprios tokenizadores.

POR QUE A DIVISÃO NÃO É POR PALAVRA

- Vocabulário aberto.** nome próprio, erro de digitação e palavra nova ficam fora de qualquer lista fechada
- Morfologia do português.** uma raiz gera dezenas de formas flexionadas, e cada forma ocuparia uma posição própria
- Custo da camada de saída.** o modelo calcula uma probabilidade por token do vocabulário a cada passo

DO TEXTO AO VETOR QUE ENTRA NO MODELO

O texto	chega como uma sequência de caracteres
O tokenizador	corta a sequência em tokens do vocabulário
O índice	cada token vira a posição dele nessa lista
A tabela	o índice busca a linha que entra no modelo

O vocabulário do modelo é uma lista de pedaços de palavra, e é em pedaços dessa lista que o texto entra e sai.

Treinamento e escolha de embeddings

A tabela de embeddings é um parâmetro do modelo, com uma linha por token do vocabulário. Ela começa com valores aleatórios, e o mesmo objetivo de treino que ajusta as matrizes de atenção ajusta também essa tabela.

NO MODELO DE LINGUAGEM

Onde fica. é a primeira camada. No BERTimbau são 29.794 linhas de 768 números, cerca de 23 milhões de parâmetros

Como é treinada. pelo objetivo do próprio modelo, que é prever o token mascarado no BERT e prever o próximo token no GPT

O que produz. a linha do token é a entrada do primeiro bloco, e a saída de cada bloco é o vetor recalculado pela frase

NO MODELO DE BUSCA

Onde fica. é um modelo à parte, que recebe um trecho de texto e devolve um vetor só para ele

Como é treinada. por objetivo contrastivo sobre pares, que aproxima o par de mesmo sentido e afasta o par de sentidos diferentes

O que produz. um vetor por trecho, gravado num banco vetorial e comparado por cosseno na recuperação

QUATRO MODELOS DE EMBEDDING QUE O ALUNO CHAMA EM UMA LINHA

MODELO	DIMENSÃO	ONDE RODA	O QUE O DIFERENCIA
sentence-transformers/all-MiniLM-L6-v2	384	local	leve, treinado em inglês
intfloat/multilingual-e5-large	1.024	local	multilíngue, inclui português
BAAI/bge-m3	1.024	local	multilíngue, aceita trecho longo
text-embedding-3-small e -large	1.536 e 3.072	API	dimensão ajustável na chamada

A escolha depende da tarefa, da língua, do tamanho do trecho e da dimensão. O desempenho por tarefa e por língua muda a cada mês, e se consulta no MTEB.

Escala dos modelos de linguagem

Número de parâmetros e ano de publicação, segundo o relatório técnico de cada modelo.


MODELO	PARÂMETROS	ANO	RESULTADO DOCUMENTADO
GPT-2	1,5 bilhão	2019	um modelo treinado só para prever a próxima palavra executa tarefas sem treino específico para elas
GPT-3	175 bilhões	2020	a tarefa é descrita no prompt (o texto enviado ao modelo) com poucos exemplos, sem ajuste de pesos
DeepSeek-V3	671 bilhões, 37 por token	2024	mistura de especialistas (mixture of experts). Cada camada tem 256 blocos especialistas, um roteador escolhe 8 por token, e só esses entram no cálculo

Entre GPT-2 e GPT-3 o objetivo de treino é o mesmo, e a diferença está na escala dos dados e dos parâmetros. Entre GPT-3 e DeepSeek-V3 muda também a arquitetura: a mistura de especialistas reduz o custo de cada token, porque só uma fração dos parâmetros entra no cálculo.

Nessa ordem de grandeza, o sistema é construído sobre um modelo já treinado, e a decisão passa a ser qual modelo usar.

Lançamento do ChatGPT em 2022

Em 30 de novembro de 2022 a OpenAI lançou o ChatGPT, uma interface de conversa sobre um modelo da série GPT-3.5. A capacidade de gerar texto já estava no GPT-3, de 2020. O lançamento acrescentou o ajuste do modelo por feedback humano e o acesso pelo navegador.



Descrição da tarefa no prompt

Aprendizado em contexto (in-context learning) é a execução de uma tarefa descrita no prompt, sem atualização dos pesos do modelo. O que a instrução específica determina o uso possível da resposta.

INSTRUÇÃO CURTA

O PROMPT

Esta mensagem é spam?

Mensagem: Parabéns, você foi sorteado.
Clique no link para resgatar o prêmio.

A RESPOSTA

Sim, essa mensagem tem características típicas de spam, como o prêmio inesperado e o pedido de clique em um link...

INSTRUÇÃO DETALHADA

O PROMPT

Você classifica mensagens de um provedor de e-mail. Responda com uma única palavra, spam ou normal, sem pontuação e sem explicação. Em caso de dúvida, normal.

Mensagem: Parabéns, você foi sorteado.
Clique no link para resgatar o prêmio.

A RESPOSTA

spam

Respostas de exemplo, escritas para a explicação. A instrução da direita fixa a lista de rótulos, o formato da saída e a regra de desempate, e por isso a resposta entra num programa sem tratamento.

Nenhuma das duas instruções altera os pesos do modelo. A diferença está no texto que antecede a mensagem, e a escrita desse texto é a construção do prompt.

Demonstração 5, resolução por instrução

AO VIVO

O QUE RODA

O filtro de spam da Demonstração 1 e a recuperação de passagem da Demonstração 2 são refeitos com um modelo generativo. A entrada do modelo é uma instrução em português, sem vetorizador, sem treino e sem conjunto rotulado.

O QUE OBSERVAR

As etapas de código que saem em relação às duas primeiras demonstrações, e as que entram no lugar. A comparação é de esforço e de dependências, e não de acurácia.

As duas tarefas são executadas pelo mesmo modelo, e o que muda entre elas é o texto da instrução.

Consumo do modelo por API

O modelo pré-treinado fica no servidor de quem o treinou, e o que trafega é a mensagem enviada e o texto devolvido. O que o programa controla são os campos da chamada.

A CHAMADA E A RESPOSTA

Vai o nome do modelo, a instrução de sistema, a lista de mensagens e os parâmetros. Volta o texto, o motivo pelo qual a geração parou e a contagem de tokens de entrada e de saída, que é a unidade em que o uso é cobrado.

O HISTÓRICO VIAJA A CADA TURNO

Cada chamada é independente, e o servidor não guarda a conversa. A continuidade existe porque o programa reenvia as mensagens anteriores, e por isso os tokens de entrada crescem a cada turno.

CONTROLE DA VARIAÇÃO

Temperatura e top_p concentram ou abrem o sorteio do próximo token. Os três maiores provedores estão retirando esse controle, conferido em 24/09/2026.

Anthropic, geração 5	recusa, erro 400
Google, Gemini 3	aceita, e recomenda o padrão
OpenAI, com raciocínio	orienta remover

CONTRATO DE SAÍDA

A instrução pede o formato, e a resposta chega em JSON com campos nomeados. É o que permite a um programa consumir a saída sem leitura humana.

O acesso por API entrega a capacidade do modelo, e o contrato de saída torna a resposta consumível por um programa. Os dois juntos são o que permite construir um sistema sobre um modelo que você não treinou.

Construção de sistemas com modelos pré-treinados

A comparação da abertura listava o que cada caminho exige. Esta lista as decisões que restam em cada caminho depois que o sistema funciona.

A DECISÃO	AO TREINAR UM MODELO PARA A TAREFA	AO USAR UM MODELO PRÉ-TREINADO
Origem do comportamento na tarefa	os rótulos do conjunto de treino, sem o qual não há sistema	o texto da instrução, e o conjunto rotulado serve só para medir
Escolha do modelo	uma arquitetura, dimensionada pelo conjunto de treino disponível	um modelo entre vários já treinados, que diferem em tamanho, latência e preço por chamada
Correção de um resultado insatisfatório	rotular mais exemplos e treinar de novo	reescrever a instrução, trocar de modelo ou ajustar os pesos com um conjunto pequeno
Tipo de entrada aceito	o tipo para o qual o vetorizador foi construído, texto neste caso	texto, imagem e áudio pelo mesmo modelo, sem um vetorizador por tipo
Objeto da medição	o rótulo previsto contra o rótulo de referência, e o resultado é um número	o texto gerado contra um critério, porque não existe uma resposta única

Com um modelo pré-treinado, as decisões que restam são a escolha do modelo, a adaptação dele à tarefa e a medição do resultado.

05

Resumo

A seção reúne as representações da noite, a condição de uso de cada uma e as referências.

Representações de texto e modelo generativo

REPRESENTAÇÃO	O QUE ELA REGISTRA	CONDIÇÃO DE USO
Bag of words	quantas vezes cada palavra do vocabulário ocorre	vocabulário fechado e estável, e necessidade de explicar a decisão termo a termo
TF-IDF	a contagem, ponderada pela raridade do termo no conjunto	busca e ordenação por termo exato, com custo baixo e sem GPU
Embedding	o contexto médio em que a palavra ocorre no corpus	aproximação de textos de mesmo sentido com palavras diferentes
Self-attention	a relação entre as palavras da mesma frase	a mesma palavra tem sentidos diferentes conforme a frase
Modelo generativo	o que foi aprendido no pré-treino, acessado por instrução	execução da tarefa sem conjunto rotulado e sem treino próprio

As quatro primeiras representações continuam adequadas nas condições da terceira coluna, e o modelo generativo acrescenta a execução da tarefa sem treino próprio.

Referências

Harris, Z. S. (1954). Distributional Structure. WORD, 10(2-3), 146-162.

Sparck Jones, K. (1972). A Statistical Interpretation of Term Specificity and Its Application in Retrieval. Journal of Documentation, 28(1), 11-21.

Salton, G., Wong, A., Yang, C. S. (1975). A Vector Space Model for Automatic Indexing. Communications of the ACM, 18(11), 613-620.

Mikolov, T. et al. (2013). Efficient Estimation of Word Representations in Vector Space. ICLR 2013, Workshop Track. arXiv:1301.3781.

Mikolov, T. et al. (2013). Distributed Representations of Words and Phrases and their Compositionality. NIPS 26.

Rong, X. (2014). word2vec Parameter Learning Explained. Preprint, arXiv:1411.2738.

Hartmann, N. et al. (2017). Portuguese Word Embeddings: Evaluating on Word Analogies and Natural Language Tasks. STIL 2017.

Vaswani, A. et al. (2017). Attention Is All You Need. NIPS 30. arXiv:1706.03762.

Radford, A. et al. (2019). Language Models are Unsupervised Multitask Learners. Relatório técnico, OpenAI.

Devlin, J. et al. (2019). BERT: Pre-training of Deep Bidirectional Transformers for Language Understanding. NAACL-HLT 2019.

Clark, K. et al. (2019). What Does BERT Look At? An Analysis of BERT's Attention. BlackboxNLP 2019, ACL.

Kovaleva, O. et al. (2019). Revealing the Dark Secrets of BERT. EMNLP-IJCNLP 2019.

Souza, F., Nogueira, R., Lotufo, R. (2020). BERTimbau: Pretrained BERT Models for Brazilian Portuguese. BRACIS 2020, LNCS 12319.

Brown, T. B. et al. (2020). Language Models are Few-Shot Learners. NeurIPS 33. arXiv:2005.14165.

Ouyang, L. et al. (2022). Training Language Models to Follow Instructions with Human Feedback. NeurIPS 35. arXiv:2203.02155.

OpenAI (2022). Introducing ChatGPT. Publicação institucional, 30/11/2022.

DeepSeek-AI (2024). DeepSeek-V3 Technical Report. Preprint, arXiv:2412.19437.

A lista completa, com as anotações e os links, está no arquivo de referências da disciplina.

Avaliação da aula no Experience Survey

A pesquisa de avaliação fica disponível ao fim de cada aula, pelo aplicativo da FIAP ou pelo site.


1 Entrar no FIAP, pelo aplicativo ou pelo site

2 Abrir o menu

3 Clicar em Experience Survey

A resposta é anônima e leva menos de cinco minutos.

Experience Survey



Obrigado!

prof. Thiago Nascimento Nogueira

e-mail: profthiago.nogueira@fiap.com.br

linkedIn: <https://www.linkedin.com/in/thnogueira/>

FIAP