

MBA AI ENGINEERING & MULTI-AGENTS • MÓDULO AI AGENTS

Generative Models

## AULA 2

# Modelos de linguagem grandes e pequenos

O que o tamanho compra, e onde o modelo roda

prof. Thiago Nascimento Nogueira

e-mail: [profthiago.nogueira@fiap.com.br](mailto:profthiago.nogueira@fiap.com.br)

linkedin: <https://www.linkedin.com/in/thnogueira/>

# Do vetor de palavras ao modelo pré-treinado

- |   |                      |                                                                                     |
|---|----------------------|-------------------------------------------------------------------------------------|
| 1 | Bag of words         | contagem de cada palavra do vocabulário no documento                                |
| 2 | TF-IDF               | a contagem ponderada pela raridade do termo no conjunto                             |
| 3 | Embedding            | um vetor por palavra, aprendido a partir das palavras vizinhas                      |
| 4 | Transformer          | self-attention, que recalcula o vetor de cada palavra a partir das outras da frase  |
| 5 | Pré-treino           | um modelo que continua texto, treinado sobre um corpus amplo                        |
| 6 | Ajuste por instrução | o modelo passa a responder a uma instrução escrita, e a tarefa é descrita no prompt |

A Aula 1 terminou com o modelo executando a tarefa a partir de uma instrução escrita. Esta noite começa nesse ponto.

# Mapa da noite

- |   |                                        |                                                                                 |
|---|----------------------------------------|---------------------------------------------------------------------------------|
| 1 | <b>Introdução a prompt engineering</b> | o texto que antecede a mensagem determina a tarefa e o uso possível da resposta |
| 2 | <b>Modelos de linguagem por porte</b>  | o que é um modelo grande e um pequeno, e o que o número de parâmetros determina |
| 3 | <b>Origem da capacidade</b>            | o que permite a um modelo menor entregar o que antes exigia um maior            |
| 4 | <b>O que cresce com o porte</b>        | o que um modelo maior compra, e o que o menor já entrega                        |
| 5 | <b>CrITÉrios de escolha do modelo</b>  | tarefa, qualidade exigida, custo por tarefa aceita e roteamento entre modelos   |
| 6 | <b>Lugar de execução</b>               | serviço por API, notebook, sistema operacional e câmera                         |
| 7 | <b>Diagnóstico da limitação</b>        | que intervenção resolve a falha observada, e em que aula ela é tratada          |

# 01

## Introdução a prompt engineering

O modelo pré-treinado executa a tarefa descrita no prompt. O texto que antecede a mensagem determina a tarefa, o formato da resposta e o uso possível dela.

## Descrição da tarefa no prompt

Aprendizado em contexto (in-context learning) é a execução de uma tarefa descrita no prompt, sem atualização dos pesos do modelo. O que a instrução específica determina o uso possível da resposta.

### INSTRUÇÃO CURTA

#### O PROMPT

Esta mensagem é spam?

Mensagem: Parabéns, você foi sorteado.  
Clique no link para resgatar o prêmio.

#### A RESPOSTA

Sim, essa mensagem tem características típicas de spam, como o prêmio inesperado e o pedido de clique em um link...

### INSTRUÇÃO DETALHADA

#### O PROMPT

Você classifica mensagens de um provedor de e-mail. Responda com uma única palavra, spam ou normal, sem pontuação e sem explicação. Em caso de dúvida, normal.

Mensagem: Parabéns, você foi sorteado.  
Clique no link para resgatar o prêmio.

#### A RESPOSTA

**spam**

Respostas de exemplo, escritas para a explicação. A instrução da direita fixa a lista de rótulos, o formato da saída e a regra de desempate, e por isso a resposta entra num programa sem tratamento.

**Nenhuma das duas instruções altera os pesos do modelo. A diferença está no texto que antecede a mensagem, e a escrita desse texto é a construção do prompt.**

# Panorama das técnicas de prompt

Prompt engineering é a escrita do texto enviado ao modelo para obter a resposta pretendida. As técnicas abaixo alteram esse texto. Nenhuma altera os pesos do modelo.

| TÉCNICA                                 | DEFINIÇÃO                                                                         | O QUE MUDA NO PROMPT                                                         |
|-----------------------------------------|-----------------------------------------------------------------------------------|------------------------------------------------------------------------------|
| Zero, one e few-shot                    | instrução sem exemplo, com um exemplo ou com vários exemplos resolvidos da tarefa | pares de entrada e saída antes do caso a resolver                            |
| Cadeia de raciocínio (chain-of-thought) | pedido de que o modelo escreva os passos antes da resposta final                  | uma instrução de raciocinar passo a passo, ou exemplos que mostram os passos |
| Atribuição de papel (role prompting)    | descrição de quem responde, para quem e em que contexto                           | uma persona e o contexto de uso no início do prompt                          |
| Saída estruturada                       | formato declarado para a resposta, como JSON com campos nomeados                  | o esquema da resposta e a regra para campo ausente                           |
| Decomposição da tarefa                  | tarefa dividida em subtarefas encadeadas, cada uma com prompt próprio             | várias chamadas, e a saída de uma entra na seguinte                          |

O texto do prompt é a primeira variável de controle sobre um modelo pronto, e a mais barata de mudar.

# Demonstração 1, execução de tarefa por instrução

AO VIVO

## O QUE RODA

Um modelo de fronteira por API executa duas tarefas da Aula 1 a partir de uma instrução em português: o filtro de spam sobre 50 mensagens e a extração de campos de 12 contratos. Cada tarefa roda com duas instruções, uma curta e uma detalhada, e o modelo é o mesmo em todas as chamadas.

## O QUE OBSERVAR

A chamada por API por extenso, com o motivo da parada e a contagem de tokens. A contagem de respostas que entram num programa sem tratamento com cada instrução. Os campos que chegam no formato declarado com o contrato de saída em JSON.

**O modelo é o mesmo em todas as chamadas, e o que muda entre as respostas é o texto da instrução.**

# 02

## Modelos de linguagem por porte

A ementa fala em GPT-4 contra Llama 3 de 8B. O que distingue um modelo grande de um pequeno, e o que o número de parâmetros determina de forma direta.

# Definição de LLM e SLM

A literatura usa o termo modelo de linguagem pequeno (small language model, SLM) sem um limiar único. Cada fonte fixa a fronteira por um critério próprio.

| FONTE                        | FRONTEIRA                                                                  |
|------------------------------|----------------------------------------------------------------------------|
| Lu et al. (2024)             | 100 milhões a 5 bilhões de parâmetros, 70 modelos abertos                  |
| Nguyen et al. (2024)         | depende do contexto e do momento. o GPT-2 de 1,5B era grande em 2019       |
| Wang et al. (2024)           | por tarefa e por recurso. registra limites de 1B e de 10B na literatura    |
| Belcak et al., NVIDIA (2025) | cabe em dispositivo de consumo com latência prática. abaixo de 10B em 2025 |

CONVENÇÃO DESTA NOITE

**Modelo pequeno**  
pesos abertos, roda na GPU de um Colab. Nesta noite, 1,7 e 4 bilhões de parâmetros.

**Modelo grande**  
acessado por API, porte não publicado pelo fornecedor. Nesta noite, dois portes de preço da mesma família.

A fronteira entre grande e pequeno é convencional e se desloca com o tempo. O que não muda é o que o número de parâmetros determina.

# Efeitos diretos do número de parâmetros

Cada parâmetro é um número armazenado e lido a cada token gerado. Três grandezas seguem diretamente da contagem de parâmetros.

## MEMÓRIA PARA CARREGAR

*2 bytes por parâmetro em bfloat16*

1,7B → 3,4 GB

8B → 16 GB

70B → 140 GB

Em 4 bits, um quarto disso: o 8B cabe em 4,5 GB.

## CUSTO POR TOKEN

*proporcional aos parâmetros ativos na geração*

O preço de API acompanha o porte. Na mesma família, em 29/09/2026, por milhão de tokens:

Haiku 4.5: entrada US\$ 1, saída US\$ 5

Sonnet 5: entrada US\$ 2, saída US\$ 10

Opus 5.5: entrada US\$ 4, saída US\$ 20

## LATÊNCIA

*cada token gerado lê os pesos inteiros*

Tokens por segundo ≈ banda de memória ÷ tamanho do modelo em bytes.

7B em 4 bits (cerca de 4 GB) numa banda de 153 GB/s: cerca de 38 tokens por segundo no limite.

**Memória, custo por token e latência seguem do número de parâmetros. A qualidade da resposta não segue só dele.**

# Famílias e portes em uso

| FAMÍLIA             | MODELOS ATUAIS                    | PORTES                  | ACESSO         | LANÇAMENTO  |
|---------------------|-----------------------------------|-------------------------|----------------|-------------|
| GPT (OpenAI)        | GPT-5.6 Luna, Terra e Sol         | não publicado           | API            | 07/2026     |
| Claude (Anthropic)  | Haiku 4.5, Sonnet 5, Opus 5.5     | não publicado           | API            | 2025 e 2026 |
| Gemini (Google)     | 3.1 Flash-Lite e Pro, Gemini Nano | não publicado           | API e aparelho | 2026        |
| Llama (Meta)        | Llama 3.2 e 3.1                   | 1B, 3B, 8B, 70B e 405B  | pesos abertos  | 2024        |
| Qwen (Alibaba)      | Qwen3 e Qwen3.5 Small             | 0,6B a 235B e 0,8B a 9B | pesos abertos  | 2025 e 2026 |
| Phi (Microsoft)     | Phi-4 e Phi-4-mini                | 14B e 3,8B              | pesos abertos  | 2024 e 2025 |
| Gemma (Google)      | Gemma 4                           | E2B, E4B, 26B-A4B e 31B | pesos abertos  | 03/2026     |
| Ministral (Mistral) | Ministral 3                       | 3B, 8B e 14B            | pesos abertos  | 12/2025     |

Consulta em 29/09/2026 às páginas dos fornecedores. A tabela envelhece. a coluna de acesso é a que decide a seção 6.

Toda família em uso oferece portes abaixo de 10 bilhões de parâmetros. A escolha não é entre ter ou não ter um modelo pequeno, e sim entre portes.

## Formas de acesso e de execução de um modelo

| FORMA                             | PESOS                               | QUEM OPERA                              | COMO SE PAGA                              | LATÊNCIA                               | LIMITE DE PORTE                        |
|-----------------------------------|-------------------------------------|-----------------------------------------|-------------------------------------------|----------------------------------------|----------------------------------------|
| Serviço por API                   | abertos ou fechados, no fornecedor  | o fornecedor                            | por token de entrada e de saída           | rede e fila do serviço                 | nenhum, na prática                     |
| Servidor próprio                  | abertos, no servidor                | a organização                           | por hardware e por operação               | rede interna                           | as GPUs disponíveis                    |
| Notebook                          | abertos, no disco                   | o usuário                               | hardware já pago. custo por token zero    | local, limitada pela banda de memória  | memória unificada. 7B a 70B quantizado |
| Dispositivo e sistema operacional | abertos ou do fornecedor do sistema | o fornecedor do sistema ou o aplicativo | custo por token zero para o desenvolvedor | local, com limite térmico e de bateria | cerca de 3B                            |

Pesos abertos abrem as três formas locais. Sem eles, resta o serviço por API, e a escolha do porte é do fornecedor.


# 03

## Origem da capacidade

Um modelo de 8 bilhões de parâmetros em 2026 resolve o que exigia 175 bilhões em 2020. Quatro mecanismos explicam de onde vem essa capacidade. Nesta noite, o nome e o efeito de cada um.

## Orçamento de treino: parâmetros contra dados

Lei de escala (scaling law): a perda do modelo cai como lei de potência com parâmetros, dados e computação. Com orçamento fixo, existe um ponto ótimo entre tamanho do modelo e quantidade de tokens de treino.



MMLU (Massive Multitask Language Understanding): 57 matérias em múltipla escolha, medida em % de acerto.

**Um modelo menor treinado com muito mais dados alcança o que um maior treinado com poucos dados entrega, e custa menos a cada chamada.**

### COMO LER O GRÁFICO

**Linha tracejada.** ótimo de treino sob orçamento fixo de computação: 20 tokens por parâmetro.

**Abaixo da linha.** menos dados que o ótimo para o tamanho. Gopher.

**Sobre a linha.** no ótimo. Chinchilla, com o mesmo orçamento do Gopher, quatro vezes menor e 7,5 pontos a mais no MMLU.

**Acima da linha.** treinado além do ótimo de treino. Quando o modelo vai ser servido bilhões de vezes, o custo de cada chamada pesa mais que o de treinar, e compensa um modelo menor com muito mais dados (Sardana et al. 2024). Llama 3 8B.

Limite da conclusão: os estudos comparam receitas de treino com orçamento fixo. Nenhum deles diz que reduzir os parâmetros de um modelo pronto o melhora.

# Qualidade dos dados de treino

Modelos da família Phi são treinados sobre dados filtrados por qualidade e dados sintéticos com estrutura de livro didático, em vez de texto da web em volume. O resultado em benchmark se aproxima de modelos várias vezes maiores.

| BENCHMARK                                | PHI-3-MINI 3,8B | MIXTRAL 8x7B | GPT-3.5 | LEITURA                    |
|------------------------------------------|-----------------|--------------|---------|----------------------------|
| MMLU (conhecimento e raciocínio, 5-shot) | 68,8            | 70,5         | 71,4    | empate com modelos maiores |

| BENCHMARK                                     | PHI-4 14B | GPT-4o | LEITURA                |
|-----------------------------------------------|-----------|--------|------------------------|
| GPQA (perguntas científicas de pós-graduação) | 56,1      | 50,6   | o menor supera o maior |

|                                 |     |      |                               |
|---------------------------------|-----|------|-------------------------------|
| SimpleQA (fatos de cauda longa) | 3,0 | 39,4 | o menor não armazena os fatos |
|---------------------------------|-----|------|-------------------------------|

MMLU: 57 matérias em múltipla escolha, em % de acerto. GPQA: questões de múltipla escolha em biologia, física e química, nível de pós-graduação, escritas para resistir à busca na web. SimpleQA: perguntas factuais curtas com uma resposta só, que medem o que o modelo armazena. Limite da conclusão: resultado em benchmark, com a discussão sobre contaminação dos dados de teste declarada pelos autores.

A seleção dos dados de treino substitui parte do tamanho em raciocínio, e não substitui o tamanho em conhecimento factual.

# Destilação e poda como origem de modelos pequenos

Parte dos modelos pequenos atuais não é treinada do zero. Eles são derivados de um modelo maior da mesma família, por dois procedimentos.

## DESTILAÇÃO (KNOWLEDGE DISTILLATION)

O modelo menor é treinado para reproduzir as saídas do modelo maior, e não só a próxima palavra do corpus.

### EXEMPLOS

Gemma 2 em 2B e 9B, treinados por destilação em vez de previsão da próxima palavra (Google, 2024).

DeepSeek-R1-Distill-Qwen-7B, com as respostas de raciocínio do DeepSeek-R1 (2025).

## PODA (PRUNING)

Parâmetros do modelo maior são removidos por um critério de importância, e o modelo resultante é retreinado com poucos dados.

### EXEMPLOS


Llama 3.2 em 1B e 3B, obtidos por poda estruturada do Llama 3.1 8B e retreino com as saídas do 8B e do 70B (Meta, 25/09/2024).

Minitron (NVIDIA, 2024): até 40 vezes menos tokens de treino que treinar do zero.

**O modelo pequeno herda parte da capacidade do maior. O custo de treino cai, e o porte na inferência é o do pequeno.**

## Densidade de capacidade ao longo do tempo

Densidade de capacidade (capability density): a razão entre o tamanho efetivo de um modelo, medido pelo resultado em benchmark contra uma curva de referência, e o seu tamanho real. Um modelo de 8B com o resultado de um modelo de referência de 16B tem densidade 2. A referência é uma família de modelos pequenos treinados pelos autores do estudo, com a curva de escala ajustada sobre eles.



**O porte necessário para um dado resultado cai com o tempo. A escolha de modelo feita hoje tem prazo de validade.**

### O QUE O ESTUDO MEDIU

51 modelos abertos de base, do Llama 1 (2023) em diante, em cinco benchmarks (MMLU, BBH, MATH, HumanEval e MBPP).

Resultado: a densidade máxima dobra a cada 3,5 meses. A cada 3,5 meses, o mesmo resultado cabe em metade dos parâmetros.

Os três pontos são os modelos com densidade relatada no texto. A reta é a tendência do estudo, ancorada no Llama 1. O MiniCPM 1 2,4B (02/2024) iguala o Mistral 7B com 35% dos parâmetros, sem densidade relatada.

*Limite da conclusão: observação empírica sobre os modelos, os benchmarks e o período do estudo. A versão preliminar do artigo, com 29 modelos, encontrou 3,3 meses.*

# 04

## O que cresce com o porte

Se um modelo pequeno alcança o resultado de um grande em vários benchmarks, o que continua a crescer com o porte, e o que o pequeno já entrega.

# Conhecimento factual e raciocínio em cadeia longa

Duas capacidades crescem com o porte: o conhecimento armazenado nos parâmetros e o raciocínio que atravessa muitos passos dependentes.

## CONHECIMENTO FACTUAL (ALLEN-ZHU E LI 2024; MALLÉN ET AL. 2023)

Cerca de 2 bits de conhecimento factual por parâmetro, quando o fato aparece mil vezes no treino.

**1,7B**      425 MB de fatos

**8B**      2 GB de fatos

**70B**      17,5 GB de fatos

Nas 4.000 perguntas menos populares do PopQA, modelos de 6B, 20B e o GPT-3 acertam 15%, 16% e 19%. Um modelo de 2,7B com trechos recuperados supera o GPT-3 sem recuperação. SimpleQA: phi-4 14B 3,0% contra 39,4% do GPT-4o.

## CADEIA LONGA DE PASSOS (BFCL V4, 12/04/2026)

| MODELO                    | MULTI-TURNO | MEMÓRIA | GERAL |
|---------------------------|-------------|---------|-------|
| Claude Opus 4.5           | 68,4        | 73,8    | 77,5  |
| Claude Haiku 4.5          | 53,6        | 54,4    | 68,7  |
| xLAM-2 8B (especializado) | 70,0        | 14,0    | 46,7  |
| Qwen3 8B                  | 41,8        | 14,6    | 42,6  |

Acurácia em %. Multi-turno: várias chamadas de função numa conversa. Memória: informação de turnos anteriores usada muitos passos depois. O 8B especializado passa o de fronteira em chamada de função encadeada e fica a 60 pontos dele quando precisa lembrar ao longo de muitos passos.

Fato raro e cadeia longa de passos crescem com o porte. Texto fornecido na chamada compensa o primeiro, e só o modelo maior entrega o segundo.

## Tarefas fechadas e o eixo da especialização

Tarefa fechada: o espaço de resposta é restrito, a informação necessária está na entrada e a instrução fixa o formato. Extração de campos, classificação e resposta apoiada em texto fornecido são exemplos.

### EVIDÊNCIA COM MODELOS AJUSTADOS (LORA LAND 2024)

310 modelos de 2B e 7B ajustados com LoRA em 31 tarefas.

Em média, 34 pontos acima do modelo base e 10 pontos acima do GPT-4.

O GPT-4 vence em 6 das 31 tarefas, entre elas código em Python e MMLU: as de domínio amplo.

### DOIS EIXOS INDEPENDENTES

|         | genérico                    | especializado                       |
|---------|-----------------------------|-------------------------------------|
| pequeno | Qwen3-1.7B e 4B nesta noite | modelos do LoRA Land, xLAM-2 8B     |
| grande  | Haiku e Sonnet nesta noite  | modelo grande ajustado a um domínio |

LoRA Land: modelos pequenos ajustados um a um para uma tarefa de texto, como classificar, extrair entidades ou resumir. xLAM-2 8B: modelo pequeno ajustado para chamar funções e ferramentas.

**Em tarefa fechada, o modelo pequeno entrega o mesmo que o grande. Porte e especialização são propriedades independentes, e a ementa as junta.**

# Dependência entre técnica de prompt e porte do modelo

O efeito de uma técnica de prompt depende do porte do modelo em que ela é aplicada. A mesma técnica ajuda um porte, e é neutra ou prejudica outro.

| TÉCNICA                                         | EFEITO NO MODELO PEQUENO                                                                                                                                          | EFEITO NO MODELO GRANDE                                                     | FONTE      |
|-------------------------------------------------|-------------------------------------------------------------------------------------------------------------------------------------------------------------------|-----------------------------------------------------------------------------|------------|
| Exemplos no prompt (few-shot)                   | Ajuda em média (9,6 pontos) e numa tarefa derruba o resultado pela metade (42,7 para 22,0). Modelo de 125M.                                                       | Ajuda mais (15,0 pontos) e em todas as tarefas. Modelo de 175B.             | Brown 2020 |
| Cadeia de raciocínio                            | Piora (4,9 para 4,1). Modelo de 8B.                                                                                                                               | Triplica o acerto (17,9 para 56,9). Modelo de 540B.                         | Wei 2022   |
| Formato do prompt (espaços, separadores, ordem) | O mesmo prompt com formatação diferente dá resultados que variam até 76 pontos, para cima ou para baixo, sem regra que diga qual formato é melhor. Modelo de 13B. | A variação continua. Aumentar o porte ou o número de exemplos não a remove. | Sclar 2024 |

Números medidos em cada estudo com a mesma tarefa nos dois portes. O ganho da cadeia de raciocínio em modelos pequenos mudou desde 2022 em matemática (Sprague et al. 2025), e continua pequeno ou nulo fora dela.

A técnica de prompt se mede no modelo em que vai ser usada. O resultado obtido num porte não se transfere a outro.

## Demonstração 2, três atividades em quatro modelos

AO VIVO

### O QUE RODA

Três atividades sobre contratos de prestação de serviços, cada uma rodada nos mesmos quatro modelos: Qwen3-1.7B e Qwen3-4B na GPU do Colab, Claude Haiku 4.5 e Claude Sonnet 5 por API. Extração de campos em quatro contratos. Pergunta com cálculo em três casos de complexidade crescente. Detecção de contradição em três casos, com o último repetido cinco vezes nos modelos de API.

### O QUE OBSERVAR

Na extração, os quatro modelos próximos. No cálculo, o caso em que cada modelo pequeno para de acertar. Na contradição, o valor escrito na cláusula aceito sem conferência pelos modelos abertos e a variação entre execuções que separa os dois modelos de fronteira. O tempo por resposta na GPU.

**A tarefa decide o porte, e a repetição decide entre dois modelos que acertam em uma execução.**

# 05

## Critérios de escolha do modelo

Entre portes que atendem à tarefa, o que decide a escolha: a qualidade exigida, o custo por tarefa aceita, o tempo de resposta e o lugar em que o modelo roda.

# Camadas de um produto de chat sobre o modelo

Um produto de chat é um sistema construído em torno do modelo. O que o usuário vê é a soma das camadas. O que a noite compara é a primeira delas.

| CAMADA                   | O QUE FAZ                                                             | EXEMPLO                                                                            |
|--------------------------|-----------------------------------------------------------------------|------------------------------------------------------------------------------------|
| Modelo                   | gera a resposta a partir do prompt                                    | Sonnet 5, GPT-5.6, Qwen3                                                           |
| Instrução de sistema     | fixa papel, regras e formato em toda conversa                         | instruções fixas do produto, enviadas ao modelo junto com cada mensagem do usuário |
| Ferramentas              | chamadas a busca, código, arquivos e serviços externos                | busca na web, execução de código                                                   |
| Memória e recuperação    | traz conversas anteriores e documentos para o prompt                  | memória entre sessões, arquivos anexados                                           |
| Roteamento entre modelos | escolhe o modelo por chamada, por custo e dificuldade                 | ChatGPT com GPT-5 (08/2025). gateway da AT&T                                       |
| Controle de raciocínio   | define se o modelo raciocina antes de responder, e por quantos tokens | níveis de raciocínio no seletor do ChatGPT                                         |
| Moderação                | filtra entrada e saída por política de uso                            | recusa e classificação de conteúdo                                                 |
| Interface multimodal     | aceita e produz imagem, áudio e arquivo                               | foto de um contrato como entrada                                                   |

A capacidade que o usuário atribui ao modelo é, em parte, do produto. A escolha desta noite é do modelo.

## Requisitos que decidem a escolha

A escolha de um modelo é uma resposta a seis perguntas sobre a aplicação. O porte é consequência das respostas, e não o ponto de partida.

|   |                    |                                                                                                                                       |
|---|--------------------|---------------------------------------------------------------------------------------------------------------------------------------|
| 1 | Natureza da tarefa | A tarefa é fechada, com a informação na entrada e o formato fixado, ou exige conhecimento próprio do modelo e cadeia longa de passos? |
| 2 | Qualidade exigida  | Qual taxa de erro a aplicação tolera, e quem revisa o que o modelo produz?                                                            |
| 3 | Volume             | Quantas chamadas por dia, e quantos tokens em cada uma?                                                                               |
| 4 | Tempo de resposta  | A resposta é lida por uma pessoa esperando, ou processada em lote?                                                                    |
| 5 | Custo              | Quanto pode custar cada tarefa aceita, dado o volume e o orçamento da aplicação?                                                      |
| 6 | Lugar de execução  | Onde a chamada pode rodar: serviço por API, servidor próprio, notebook ou dispositivo?                                                |

**Os requisitos vêm da aplicação. O porte do modelo é a última decisão, e não a primeira.**

# Taxa de aceitação e custo por tarefa aceita

Duas medidas comparam modelos sobre o mesmo lote de tarefas, com o critério de aceitação definido antes da comparação.

TAXA DE ACEITAÇÃO

**tarefas aceitas ÷ tarefas avaliadas**

*a fração do lote que atende ao critério de aceitação*

CUSTO POR TAREFA ACEITA

**custo do lote ÷ tarefas aceitas**

*quanto custa cada resultado aproveitável, e não cada chamada*

EXEMPLO COM NÚMEROS CRIADOS PARA A EXPLICAÇÃO, LOTE DE 1.000 TAREFAS


| CONFIGURAÇÃO                | CUSTO DO LOTE | TAREFAS ACEITAS | TAXA DE ACEITAÇÃO | CUSTO POR TAREFA ACEITA |
|-----------------------------|---------------|-----------------|-------------------|-------------------------|
| Modelo pequeno, local       | R\$ 12        | 900             | 90%               | R\$ 0,013               |
| Modelo de fronteira, barato | R\$ 60        | 980             | 98%               | R\$ 0,061               |
| Modelo de fronteira, caro   | R\$ 120       | 990             | 99%               | R\$ 0,121               |

Leitura do exemplo: o modelo caro custa dez vezes mais por lote e nove vezes mais por tarefa aceita, para 9 pontos de taxa a mais. A medida se chama custo por tarefa aceita, e vira custo total quando incluir a revisão humana das tarefas recusadas e a manutenção da solução.

Com critério de aceitação fixado antes, a comparação entre modelos vira duas divisões, e a decisão passa a ter número.

# Roteamento e cascata entre modelos

Roteamento (routing): a escolha do modelo é feita a cada chamada, por um critério de custo e de dificuldade. Cascata (cascade): o modelo menor responde primeiro, e o maior entra quando a resposta não passa num critério.



| FONTE                                | RESULTADO PUBLICADO                                                                                                                                      |
|--------------------------------------|----------------------------------------------------------------------------------------------------------------------------------------------------------|
| FrugalGPT (Chen, Zaharia e Zou 2024) | iguala o GPT-4 com até 98% de redução de custo, por cascata sobre modelos mais baratos                                                                   |
| RouteLLM (Ong et al. 2025)           | custo reduzido em mais de duas vezes em certos casos, sem queda de qualidade, com roteador treinado em preferências                                      |
| AT&T (07/2026)                       | gateway que escolhe o modelo por chamada, pesando velocidade, custo e qualidade esperada, com 45 bilhões de tokens por dia e redução de custo de até 90% |

A escolha entre grande e pequeno deixa de ser uma decisão única e passa a ser feita a cada chamada, por um critério explícito.

# 06

## Lugar de execução

O modelo de linguagem passou a caber no notebook, no sistema operacional, no navegador e na câmera. O que muda no desenho da aplicação quando a capacidade está perto do usuário e do equipamento.

# Geração limitada pela banda de memória

Para gerar um token, o processador lê todos os pesos do modelo da memória. O limite superior de tokens por segundo é a banda de memória dividida pelo tamanho do modelo em bytes.

**tokens por segundo (teto) = banda de memória (GB/s) ÷ tamanho do modelo (GB)**

| CHIP         | BANDA (APPLE) | MODELO 7B, 4 BITS | TETO CALCULADO | MEDIDO (LLAMA.CPP) |
|--------------|---------------|-------------------|----------------|--------------------|
| Apple M5     | 153 GB/s      | cerca de 4 GB     | 38 tokens/s    | 32 tokens/s        |
| Apple M5 Pro | 307 GB/s      | cerca de 4 GB     | 77 tokens/s    | 66 tokens/s        |
| Apple M5 Max | 614 GB/s      | cerca de 4 GB     | 154 tokens/s   | 120 tokens/s       |

O medido fica abaixo do teto porque a geração também calcula e não só lê. Um modelo de 70B em 4 bits ocupa cerca de 40 GB: no M5 Max, teto de 15 tokens por segundo. no M5, não cabe na memória.

No notebook, o porte do modelo é limitado pela memória, e a velocidade pela banda. A quantização reduz os dois ao mesmo tempo.

# Modelo embarcado no dispositivo


Sistema operacional, navegador e câmera instalam um modelo de linguagem no próprio equipamento e o expõem por uma API local. O modelo roda sem rede e sem custo por token, dentro dos limites da coluna da direita.

| PLATAFORMA                | MODELO E ACESSO                                                                                                    | PORTE         | LIMITE DOCUMENTADO                                                            |
|---------------------------|--------------------------------------------------------------------------------------------------------------------|---------------|-------------------------------------------------------------------------------|
| Apple (iOS, macOS)        | Foundation Models framework, AFM 3 Core no aparelho, Private Cloud Compute na nuvem                                | 3B denso      | contexto de 4.096 tokens no iOS 26 e 8.192 no iOS 27. 32.768 na nuvem privada |
| Android                   | Gemini Nano pelo AICore e ML Kit GenAI. Firebase AI Logic com modo híbrido                                         | não publicado | modos PREFER_ON_DEVICE e PREFER_IN_CLOUD declarados pelo aplicativo           |
| Windows                   | Phi Silica pelo Windows App SDK, substituído pelo Aion Instruct em 11/2026. Foundry Local para modelos abertos     | não publicado | exige Copilot+ PC com NPU                                                     |
| Chrome                    | Prompt API com Gemini Nano, estável no Chrome 148                                                                  | não publicado | 22 GB livres e GPU com mais de 4 GB de VRAM, ou 16 GB de RAM                  |
| Câmera (i-PRO, Hailo-10H) | modelo de visão-linguagem no equipamento, interação por texto livre. Ao serviço central vão alertas, e não o vídeo | cerca de 2B   | acelerador de 2,5 W, mais de 10 tokens por segundo                            |

O custo por token zero e a ausência de rede mudam o desenho: a parte da aplicação que cabe nesses limites passa a rodar no equipamento.

# Arquitetura híbrida com regra declarada e limites documentados

Arquitetura híbrida: o modelo do aparelho responde primeiro, e a chamada sobe ao serviço central quando uma regra declarada é acionada. A regra é parte do desenho, e não um detalhe de implementação.



A regra de subida é o degrau em que o modelo local para de acertar, escrito no código da aplicação.

# 07

## Diagnóstico da limitação

Quando um modelo falha numa tarefa, a intervenção certa depende da causa. Quatro hipóteses, e a aula em que cada resposta é tratada.

# Hipótese sobre a limitação e mapa da disciplina

Uma falha observada admite quatro causas. Cada uma tem um sinal no resultado, uma intervenção própria e uma aula em que a intervenção é tratada. Trocar de modelo é a resposta a uma delas.

| HIPÓTESE                | SINAL NO RESULTADO                                                                 | INTERVENÇÃO                                                                 | ONDE                                                    |
|-------------------------|------------------------------------------------------------------------------------|-----------------------------------------------------------------------------|---------------------------------------------------------|
| Informação ausente      | a resposta inventa um dado que não está na entrada, ou erra um fato de cauda longa | fornecer o texto na chamada. Recuperação de conteúdo externo                | outra disciplina (RAG)                                  |
| Instrução inadequada    | o modelo responde a outra pergunta, ignora o formato ou copia o exemplo            | reescrever a instrução e medir de novo no mesmo modelo                      | esta noite. Knowledge Management and Prompt Engineering |
| Capacidade insuficiente | instrução certa e informação na entrada, e o modelo erra o cálculo ou a inferência | modelo maior, ou ajuste do modelo à tarefa (fine-tuning, LoRA, QLoRA)       | esta noite. Aula 3                                      |
| Restrição de execução   | a resposta certa não cabe no tempo, na memória ou no custo                         | quantização, poda, destilação e métricas. Modelo menor com o mesmo critério | Aula 5                                                  |

Entrada ou saída com imagem ou áudio: multimodalidade, Aula 4. As decisões viram uma solução: casos de uso e projeto integrado, Aula 6.

A hipótese vem antes da técnica. Trocar de modelo resolve capacidade insuficiente, e não resolve instrução inadequada nem informação ausente.

## Laboratório 2.2, decisão com número

### EM GRUPO

#### O QUE RODA

Grupos de 2 a 4 pessoas. Cada grupo recebe os resultados já executados da escada nos quatro modelos, com o critério de aceitação de cada caso, e os preços por milhão de tokens. Ninguém treina nem avalia modelo: o grupo lê resultados e decide.

#### O QUE OBSERVAR

Para cada tipo de tarefa, o grupo calcula a taxa de aceitação e o custo por tarefa aceita de cada modelo, recomenda uma configuração e escreve a condição de revisão: "revisaríamos a escolha se este indicador deixasse de ser atendido". Durante a discussão, uma condição muda (volume, latência, categoria nova de documento), e o grupo diz se a escolha se mantém.

**A entrega é uma recomendação por tarefa com duas medidas e uma condição de revisão.**

## REFERÊNCIAS

# Referências

**Brown, T. B. et al. (2020).** Language Models are Few-Shot Learners. NeurIPS 33. arXiv:2005.14165.

**Hoffmann, J. et al. (2022).** Training Compute-Optimal Large Language Models. arXiv:2203.15556.

**Wei, J. et al. (2022).** Chain-of-Thought Prompting Elicits Reasoning in Large Language Models. NeurIPS 35.

**Mallen, A. et al. (2023).** When Not to Trust Language Models. ACL 2023. arXiv:2212.10511.

**Chen, L., Zaharia, M., Zou, J. (2024).** FrugalGPT. TMLR. arXiv:2305.05176.

**Sardana, N. et al. (2024).** Beyond Chinchilla-Optimal. ICML 2024. arXiv:2401.00448.

**Allen-Zhu, Z., Li, Y. (2024).** Physics of Language Models: Part 3.3, Knowledge Capacity Scaling Laws. arXiv:2404.05405.

**Abdin, M. et al. (2024).** Phi-3 Technical Report. arXiv:2404.14219.

**Zhao, J. et al. (2024).** LoRA Land: 310 Fine-tuned LLMs that Rival GPT-4. arXiv:2405.00732.

**Schulhoff, S. et al. (2024).** The Prompt Report: A Systematic Survey of Prompting Techniques. arXiv:2406.06608.

**Sclar, M. et al. (2024).** Quantifying Language Models' Sensitivity to Spurious Features in Prompt Design. ICLR 2024.

**Gemma Team (2024).** Gemma 2: Improving Open Language Models at a Practical Size. arXiv:2408.00118.

**Abdin, M. et al. (2024).** Phi-4 Technical Report. arXiv:2412.08905.

**Ong, I. et al. (2025).** RouteLLM: Learning to Route LLMs with Preference Data. ICLR 2025.

**Sprague, Z. et al. (2025).** To CoT or not to CoT? ICLR 2025. arXiv:2409.12183.

**Belcak, P. et al. (2025).** Small Language Models are the Future of Agentic AI. arXiv:2506.02153.

**Xiao, C. et al. (2025).** Densing law of LLMs. Nature Machine Intelligence 7, 1823-1833.

**Berkeley Function Calling Leaderboard V4 (2026).** gorilla.cs.berkeley.edu/leaderboard.html, placar de 12/04/2026.

*Fontes de fornecedores (Apple, Google, Microsoft, Anthropic, OpenAI, i-PRO, Hailo, Gartner, AT&T) citadas no rodapé de cada slide, com a data de consulta. A lista completa está no arquivo de referências da disciplina.*

# Avaliação da aula no Experience Survey

A pesquisa de avaliação fica disponível ao fim de cada aula, pelo aplicativo da FIAP ou pelo site.


1 Entrar no FIAP, pelo aplicativo ou pelo site

2 Abrir o menu

3 Clicar em Experience Survey

A resposta é anônima e leva menos de cinco minutos.

Experience Survey



# Obrigado!

prof. Thiago Nascimento Nogueira

e-mail: [profthiago.nogueira@fiap.com.br](mailto:profthiago.nogueira@fiap.com.br)

linkedIn: <https://www.linkedin.com/in/thnogueira/>

FIAP