

FIAP

NBA

ESTRUTURA DAS AULAS

Aula 01 — Transformers + Introdução a LLMs (90 min)

0–10 min: Contexto de negócio

10–35 min: Transformer

35–65 min: LLMs

65–85 min: Exemplos (GPT-2, GPT-3, DeepSeek)

85–90 min: Recap

Aula 02 — LLM vs SLM + Prompt Engineering (90 min)

0–15 min: Recap

15–45 min: LLM vs SLM

45–75 min: Prompt Engineering

75–90 min: Exercícios

Generative Models – Eu Prof.



Cientista de Computação, pós graduado em Gerenciamento Projetos de TI pela Poli-USP e Especialização em Gerenciamento de Projetos pela University of La Verne, Califórnia/EUA e professor de IoT e Tecnologias Disruptivas para alunos de Graduação da FIAP/SP.

Atuo como Gerente de Tecnologia e Inovação e quero cada vez mais implantar o IoT aos negócios com o objetivo de dar inteligência as atividades em campo.



<https://www.linkedin.com/in/andersonit>



O quanto a Inteligência Artificial
é Inteligente?

CONTEXTO DE NEGÓCIO

O Mundo Antes e Depois da GenAI

Antes: automação tradicional (RPA, scripts, chatbots de FAQ)

Agora: decisão + geração + execução com IA

Dados existem, mas estão fragmentados

Processos manuais e inconsistentes

Falta inteligência acionável


Chatbots tradicionais não resolvem o problema

Necessidade de IA que entende contexto e executa

Conexão com Quantum Commerce

Rede Neural RNN

Redes RNN (LSTM / GRU)



O QUE É UM LM

Language Model

Um Language Model (LM) é um modelo treinado para prever a próxima palavra mais provável com base no contexto anterior.

EXEMPLO

“Eu gosto de jogar _____”



PREDIÇÕES DO MODELO

Palavra	Probabilidade
Futebol	0,87
Tênis	0,70
água	0,65
Lua	0,12


COMO FUNCIONA

O modelo analisa o contexto da frase e calcula a probabilidade de cada palavra ser a próxima. Quanto maior a probabilidade, mais provável é a escolha.

→ “Futebol” tem a maior probabilidade (0,87), então seria a predição do modelo.

Large Language Model

Você é uma pessoa _____



Bonita	0,80	0,72
Linda	0,80	0,78
Maravilhosa	0,80	0,81
Divina	0,80	0,84

O QUE É TRANSFORMER

Arquitetura Transformer

Criada em 2017 pelo Google

$$QKV_{ij} = \left(\sum_{d=1}^{768} \text{Embedding}_{i,d} \cdot \text{Weights}_{d,j} \right) + \text{Bias}_j$$

Intuição Simples

O Transformer lê a frase inteira ao mesmo tempo e entende o contexto completo — diferente dos modelos anteriores, que liam palavra por palavra.

Exemplo : <https://poloclub.github.io/>

ATTENTION

O Conceito-Chave do "Attention is all you need"

Exemplo:


"A entrega atrasou, MAS o cliente ficou satisfeito"

Qual é o sentimento final?

"atrasou" → impacto negativo

"MAS" → muda o contexto (determinante)

"satisfeito" → sentimento final positivo



Insight

Transformer entende relações, não apenas palavras isoladas.

SELF-ATTENTION E VANTAGENS

Self-Attention

Cada palavra interage com todas as outras palavras da frase

O modelo calcula a importância relativa de cada palavra

Analogia: é como uma reunião onde todo mundo escuta todo mundo ao mesmo tempo

Por que isso revolucionou a IA

Paralelismo — processa tudo ao mesmo tempo

Escalabilidade — funciona com grandes volumes de dados

Entendimento de contexto — compreende relações complexas

Base para toda a IA Generativa atual

O QUE É UM LLM

Large Language Model

Modelo treinado com grandes volumes de texto

Aprende padrões de linguagem

Não “sabe” — ele prediz a próxima palavra mais provável

Como Funciona (Fluxo Simples)

Prompt → Tokens → Contexto → Previsão → Resposta

O modelo recebe a instrução, quebra em tokens e gera a resposta.

TOKENIZAÇÃO E PREDIÇÃO

Tokenização

Exemplo: “cliente insatisfeito”

→ [“cliente”, “insatisfeito”]

O texto é quebrado em tokens antes de ser processado pelo modelo.

Predição de Próxima Palavra

O modelo não “sabe” — ele “chuta com probabilidade”

Exemplo: “O cliente está...” → satisfeito? irritado?

O LLM escolhe a palavra mais provável com base no contexto.

CARACTERÍSTICAS E LIMITAÇÕES

Características dos LLMs

Generalistas — funcionam com texto aberto e diversas tarefas

Transfer learning — conhecimento é transferível entre domínios

Flexíveis — respondem a instruções em linguagem natural

Limitações

Alucinação — podem gerar informações falsas com confiança

Dependência de prompt — a qualidade da resposta depende da instrução

Falta de contexto real — sem integração, não acessam dados atualizados

Ponte com Aula 02: RAG e Prompt Engineering resolvem parte dessas limitações

EXEMPLOS DE MODELOS

GPT-2 — Prova de Conceito

~1.5B parâmetros | Texto ainda limitado | Uso experimental e acadêmico

GPT-3 — Escala

~175B parâmetros | Primeira IA “quase humana” | Base do boom de IA

DeepSeek — Eficiência

Open-source e competitivo | Foco em eficiência | Forte custo-benefício

GPT-4 (menção)

Melhor raciocínio | Multimodal | Referência atual de mercado

TAKEAWAYS AULA 01

O que levar desta aula

Transformer = base de tudo na IA moderna

LLM = previsão de linguagem em escala

Attention permite entender relações, não apenas palavras

Modelos evoluem em capacidade e custo (GPT-2 → GPT-3 → DeepSeek)

Na próxima aula: como escolher o modelo certo e como “programar” LLMs com prompts

AULA 02

LLM vs SLM + Prompt Engineering

Nesta aula vamos explorar:

Quando usar modelos grandes (LLM) vs modelos menores (SLM)

Comparação prática: GPT-4 vs Llama 3

Estratégia híbrida para produção

O que é Prompt Engineering

Estrutura de um bom prompt

Tipos: zero-shot, few-shot, chain-of-thought

Aplicação prática com o case Quantum Commerce

LLM VS SLM


Nem sempre o maior modelo é o melhor

LLM (Large Language Model):
modelos grandes como GPT-4

SLM (Small Language Model):
modelos menores como Llama 7B/8B

Comparação Prática

Qualidade:	GPT-4 (Alta) vs Llama 3 (Média)
Custo:	GPT-4 (Alto) vs Llama 3 (Baixo)
Latência:	GPT-4 (Alta) vs Llama 3 (Baixa)
Customização:	GPT-4 (Média) vs Llama 3 (Alta)



```
!pip install llama-cpp-python  
from llama_cpp import Llama
```

```
from huggingface_hub import hf_hub_download
```

```
# Define the model ID and filename  
model_id = "hugging-quants/Llama-3.2-3B-Instruct-Q4_K_M-GGUF"  
model_filename = "llama-3.2-3b-instruct-q4_k_m.gguf"
```

```
# Download the model file  
model_path = hf_hub_download(repo_id=model_id, filename=model_filename)
```

```
print(f"Model downloaded to: {model_path}")# Instanciando o modelo  
my_awesome_llama_model = Llama(model_path=model_path)
```

```
prompt = "O que é inteligencia Artificial?"  
max_tokens = 100  
temperature = 0.3  
top_p = 0.1
```

Modelo LLAMA 3

[Link para oCodigo](#)

Modelo OLLAMA 3

```
# Define the parameters
model_output = my_awesome_llama_model(
    prompt,
    max_tokens=max_tokens,
    temperature=temperature,
    top_p=top_p,
    echo=echo,
    stop=stop,
)
final_result = model_output["choices"][0]["text"].strip()

print(final_result)
```

Modelo LLM por API

 Open in Colab

[Link para o Código](#)

Instala a biblioteca oficial atualizada da Google para o Gemini

```
!pip install -q -U google-generativeai
```

```
from google import generativeai
```

Pegar dados de variáveis de ambiente

```
from google.colab import userdata
```

SUBSTITUA pelo texto da sua chave que você copiou do AI Studio

```
MINHA_CHAVE_API = userdata.get('GOOGLE_API_KEY')
```

Inicializa o cliente do Gemini

```
client = generativeai.Client(api_key=MINHA_CHAVE_API)
```

Escreva a sua pergunta aqui!

```
sua_pergunta = "Explique de forma simples o que é uma inteligência artificial Generativa."
```

Envia o pedido para o modelo mais rápido e eficiente (Gemini 2.5 Flash)

```
response = client.models.generate_content(  
    model='gemini-2.5-flash',  
    contents=sua_pergunta, )
```

Mostra a resposta gerada na tela

```
print("--- RESPOSTA DO GEMINI ---")
```

```
print(response.text)
```

ESTRATÉGIA HÍBRIDA

Quando usar GPT-4

Tarefas complexas e raciocínio multistep

Interação com usuário final

Quantum: atendimento complexo, negociação

Quando usar Llama 7B/8B

Processos internos e classificação

Automação simples, alto volume

Quantum: classificação de produtos, análise de reviews

Arquitetura Real de Mercado

GPT-4 → decisões críticas | SLM → escala e custo

PROMPT ENGINEERING

O que é Prompt Engineering?

Forma de “programar” LLMs usando linguagem natural

Entrada = instrução + contexto

Estrutura de um Bom Prompt


[Contexto] + [Tarefa] + [Formato esperado] +

[Exemplo]

Exemplo

Ruim: “resuma isso”

Bom: “Resuma em 3 bullets focando em impacto financeiro”



TIPOS DE PROMPT

Zero-shot

Sem exemplos — o modelo responde apenas com a instrução

Few-shot

Com exemplos — o modelo aprende o padrão a partir de amostras

Chain-of-thought

“Explique passo a passo” — melhora o raciocínio do modelo

Problemas Comuns

Ambiguidade na instrução

Falta de contexto

Prompt curto demais

PARÂMETROS DE PROMPT

O que é o Top-K?

O Top-K limita a escolha do modelo a um **número fixo** de palavras mais prováveis.

- **Como funciona:** Se você definir $K = 50$, o modelo vai olhar apenas as 50 melhores palavras da lista. Todas as outras são jogadas fora. A IA então sorteia uma palavra apenas entre essas 50.
- **Influência:**
 - **Valor baixo (ex: $K=5$):** O texto fica muito repetitivo, óbvio e travado.
 - **Valor alto (ex: $K=100$):** O texto ganha mais variedade, mas pode começar a inventar palavras que não fazem sentido no contexto.

O que é o Top-P (Nucleus Sampling)?

O Top-P limita a escolha com base na **soma das probabilidades** das palavras, e não em uma quantidade fixa.

- **Como funciona:** Se você definir $P = 0.90$ (ou 90%), o modelo vai somando as palavras mais prováveis da lista até a chance acumulada delas atingir 90%. O resto é descartado.
- **Influência:** A lista de escolhas muda de tamanho dinamicamente. Se o modelo tiver muita certeza do que escrever, a lista fica bem curta. Se ele estiver em dúvida, a lista aumenta para dar mais opções criativas.

E A TEMPERATURA?

Imagine que a IA precisa completar a frase: *"O gato subiu no..."*

Antes da Temperatura agir, as chances normais são:

- **telhado:** 70%
- **muro:** 20%
- **abacaxi:** 0.1%

Veja como a Temperatura muda isso:

Temperatura Baixa (0.1 a 0.5) = Foco e Lógica.

Ela deixa as palavras mais prováveis com uma chance ainda maior e esmaga as palavras raras. O modelo fica super conservador e previsível.

- *Exemplo:* **telhado** sobe para 95%, **muro** cai para 4.9% e **abacaxi** vira 0%.

Temperatura Alta (0.8 a 1.5) = Criatividade e Caos.

Ela nivela o terreno. Ela tira força das palavras óbvias e dá mais chances para as palavras esquisitas.

- *Exemplo:* **telhado** cai para 40%, **muro** vai para 35% e **abacaxi** sobe para 10%.

PROMPT + QUANTUM

Exemplo de Prompt Estruturado

“Você é um agente de atendimento.
Considere políticas de devolução.
Cliente quer cancelar compra atrasada.
Gere resposta empática + ação.”

Conexão com o Case

Transformer → entendimento de contexto do cliente

LLM → interface cognitiva

SLM → otimização de custo

Prompt → controle de comportamento

EXERCÍCIO EM SALA

Atividade Prática (15 min)

Dividir a turma em 3 grupos:

Grupo 1 → Cria prompt de vendas

Grupo 2 → Cria prompt de suporte

Grupo 3 → Cria prompt logístico

Depois

Comparar os prompts entre grupos

Identificar pontos de melhoria

Ajustar com base nos conceitos aprendidos

Como customizar um LLM com meus dados?

RAG

Pequenas bases de dados

Model as-is

Fine-tune

Médias bases de dados

Model training

Pre-train

Grandes bases de dados

TAKEAWAYS AULA 02

O que levar desta aula

LLM $\neq$ sempre a melhor opção

SLM = eficiência para tarefas específicas

Estratégia híbrida é arquitetura real de mercado

Prompt Engineering = nova forma de programar

A qualidade do prompt define a qualidade da resposta

CASE QUANTUM

- Transformer → entendimento de contexto do cliente
- LLM → interface cognitiva
- SLM → otimização de custo
- Prompt → controle de comportamento
- Agents → execução de processos



FIAP